UADB

Université Alioune Diop de Bambey
UFR-SATIC
Master I - Statistique et Informatique Décisionnelle
2017 - 2018

Séries Temporelles

Théorie et Pratique

Souleymane Fofana [1]

1. ENSAE, Immeuble ANSD, Rocade Fann Bel-air Cerf-volant, BP 45512 Dakar RP - SENEGAL, BERSTATE, Bureau d'étude et de Recherche en Statistique et Economie, berstate@yahoo.fr
e-mail : fof_sn@yahoo.fr, souleymane.fofana@ansd.sn

Objectifs du cours

Présenter les principaux modèles de séries temporelles et leurs statistiques.

Etudier les variables au cours du temps, le PIB, l'investissement, etc; quel sera niveau de croissance du Sénégal en 2020 ?

Etudier les relations entre plusieurs variables; quel est l'effet de l'investissement publique sur la croissance ?

Effectuer la prévision des réalisations futures, très souvent pour des raisons économiques (prévoir l'évolution de la vente d'un produit pour ajuster au mieux les moyens de production, prévoir l'évolution d'un produit financier,...).

Table des matières

1 Généralités sur les séries temporelles **5**
1.1 Stationnarités . . . 5
1.1.1 Stationnarité stricte . . . 5
1.1.2 Stationnarité faible . . . 5
1.1.3 Ergodicité . . . 7
1.1.4 Théorème de Wold (1954) . . . 7
1.1.5 Bruit Blanc . . . 8
1.1.6 Processus d'innovation . . . 8
1.2 Analyse temporelle . . . 9
1.2.1 Moyenne et Variance . . . 9
1.2.2 Fonction d'autocovariance . . . 9
1.2.3 Fonction d'autocorrélation (ACF) et fonction d'autocorrélation partielle (PACF) . . . 10
1.3 Outils d'analyse spectrale . . . 12
1.3.1 Densité Spectrale . . . 12
1.3.2 Corrélogramme . . . 15

2 Les processus linéaires de types ARMA **16**
2.1 Processus linéaire . . . 16
2.2 Opérateur retard . . . 17
2.3 Modèles simples : AR et MA . . . 18
2.3.1 Processus Autoregressifs (Processus AR) . . . 18
2.3.2 Processus moyenne mobile (Processus MA, Moving Average) . . . 20
2.4 Modèle composé : ARMA . . . 23
2.5 Densité spectrale des processus ARMA . . . 26
2.5.1 Densité spectrale d'un AR(p) . . . 26
2.5.2 Densité spectrale d'un MA(q) . . . 26
2.6 Extension des processus ARMA . . . 27
2.6.1 Processus ARMA intégrés : ARIMA . . . 27
2.6.2 Processus ARIMA Saisonniers : SARIMA . . . 28

3 Modélisation univariée de Box-Jenkins **30**
3.1 Les étapes de la méthode de Box-Jenkins . . . 30
3.1.1 Familiarisation avec les données . . . 30
3.1.2 Analyse préliminaire . . . 30
3.1.3 Identification ou Spécification du modèle . . . 30
3.1.4 Estimation des paramètres . . . 32
3.1.5 Validation par tests des modèles . . . 34
3.1.6 Prévision . . . 44

Introduction

La théorie des séries temporelles (ou chronologiques) s'intérresse à l'analyse statistique et probabiliste d'observations ordonnées chronologiquement. Elle est appliquée actuellement dans des domaines aussi divers que l'économétrie, la finance, la médecine, la démographie, etc, et en astronomie, en théorie du signal, en hydrologie, en météorologie etc, depuis les années 1900.
Une série temporelle à temps discret est une suite finie $(x_1, ..., x_n)$ de données indexées par le temps. L'indice peut être selon les cas la minute, l'heure, le jour, le mois, l'année, etc...

Exemple
Consommation d'électricité, vente de voiture, l'évolution du nombre de voyageur utilisant le train, l'accroissement relatif de l'indice de prix, etc...
L'étude d'une série temporelle a un double objectif : modéliser pour expliquer un phénomène observé ; prédire la série dans le futur.
Dans ce cours, nous ne considérons que des processus particuliers, supposés notamment stationnaires. Ce qui nous permettra de présenter la modélisation $ARMA$ qui sera poursuivie par l'étude de processus à plusieurs variables, les modèles VAR.

Modélisation des séries temporelles
La modélisation des séries temporelles consiste à construire un modèle statistique reliant la valeur présente de la variable endogène uniquement à ses valeurs passées ainsi qu'aux valeurs passées et présente d'une perturbation aléatoire ou aussi à l'étude des relations entre plusieurs variables. Le modèle statistique issu de cette approche est appelé modèle de série temporelle.

Le principe de la modélisation peut se résumer à ces quatres questions :
- Que signifie modéliser ?
- Pourquoi modéliser ?
- Que modélise-t-on ?
- Comment modéliser ?

La modélisation consiste à créer une représentation simplifiée d'un problème, grâce à un modèle. Ainsi, la modélisation d'un processus consiste à trouver un modèle paramétré dont le comportement dynamique approche celui du processus. Un modèle est la représentation d'un phénomène du monde réel et de son fonctionnement : quand on dispose d'un modèle, on peut simuler le comportement de ce phénomène.

La modélisation trouve sa justification dans l'explicitation et la prédiction du phénomène temporel. Très souvent pour des raisons socio-économiques, on modélise pour prévoir (le temps qu'il va faire, l'évolution des ventes d'un certain produit, prévoir la consommation d'électricité pour ajuster au mieux la production, l'évolution du prix d'un produit financier,...).

La modélisation représente le comportement d'une grandeur naturelle par une expression comportant une partie déterministe (une fonction) et une partie aléatoire.

La modélisation peut être `déterministe`, il s'agit dans ce cas d'ajuster une forme mathématique à la variation "en moyenne" du phénomène, par des méthodes que nous verrons plus loin ; `aléatoire`, dans ce cas on suppose que le phénomène varie hasardeusement autour de sa moyenne.

La modèlisation s'appuie sur différents types de modèles décrivant la façon dont la série évolue.

1 Généralités sur les séries temporelles

Une série temporelle est une suite de nombre réels, indéxés par des entiers relatifs et ordonnées chronologiquement.

Exemple
X_t revenu d'un étudiant

Une série temporelle est alors une réalisation d'un processus aléatoire.

1.1 Stationnarités

La stationnarité ou encore l'homogénéité est un concepte clé pour la validité externe d'une régression sur séries chronolgiques.
La stationnarité dit que, d'un point de vue statistique, le passé est comparable au présent et au futur. Elle assure l'utilisation du modèle en dehors de la période sur laquelle il a été estimé.

Considérons une suite de variables aléatoires $(X_t)_{t=0,1,...}$. On dit que cette suite est stationnaire en moyenne lorsque la moyenne de chacune des variables de la suite est identique :

$$E(X_t) = E(X_{t-1}) = ... = E(X_0)$$

et on dira qu'elle est stationnaire en variance lorsque la variance de chacune des variables de la suite est identique :

$$V(X_t) = V(X_{t-1}) = ... = V(X_0).$$

1.1.1 Stationnarité stricte

Un processus (X_t) est stationnaire au sens strict, si pour tout entier $n \in \mathbb{N}$, pour tout n-uplet $(t_1, t_2, ..., t_n) \in \mathbb{T}^n$ avec $t_1 < t_2 < ... < t_n$ et pour tout décalage temporel $h \in \mathbb{T}$, la loi de $(X_{t_1+h}, X_{t_2+h}, ..., X_{t_n+h})$ ne dépend pas de h.
Les vecteurs $(X_{t_1}, ..., X_{t_n})$ et $(X_{t_1+h}, ..., X_{t_n+h})$ ont la même loi de probabilité "jointe"

$$(X_{t_1}, ..., X_{t_n}) \stackrel{d}{=} (X_{t_1+h}, ..., X_{t_n+h})$$

En d'autres termes, cela signifie que $\forall$ $(x_1, ..., x_n)$, $\forall (t_1, t_2, ..., t_n)$ et $\forall h$:

$$\mathbb{P}\big(X_{t_1} < x_1, ..., X_{t_n} < x_n\big) = \mathbb{P}\big(X_{t_1+h} < x_1, ..., X_{t_n+h} < x_n\big)$$

Ceci implique aussi que tous les moments finis d'ordre n sont invariants au cours du temps. Cette définition de la stationnarité est cependant trop restrictive, difficile à atteindre (Priestley, 1988), c'est pour cela que l'on a défini la stationnarité au second ordre. Dans la suite le terme stationnarité renverra au second ordre.

1.1.2 Stationnarité faible

Un processus est dit être *stationnaire de premier ordre* si sa première fonction de moment est invariante au cours du temps, il est dit s*tationnaire au second ordre* si sa première et sa seconde fonction des moments sont invariantes au cours du temps. Un processus stationnaire de second ordre aura alors une moyenne constante, une variance constante finie et une covariance qui est une fonction de corrélation qui ne dépend que de la différence

des deux instants, c'est à dire

1. $E[X_t^2] = \mu_2 < \infty, \quad \forall\, t \in \mathbb{Z}$
2. $E[X_t] = \mu, \quad \mu \in \mathbb{R}, \quad \forall\, t \in \mathbb{Z}$
3. $Cov[X_t, X_{t+h}] = \gamma(h), \quad \forall\, t \in \mathbb{Z}.$

On remarque que la variance du processus $(X_t)_{t\in\mathbb{Z}}$ reste constant au cours du temps $V(X_t) = \sigma_X^2 = Cov(X_t, X_t) = \rho_0$, on dira que le processus est *homoscédastique*.

La stationnarité de second ordre est aussi généralement mentionnée dans la literature comme "stationnarité en covariance" ou "stationnarité faible". L'exemple le plus trivial de processus stationnaire est le bruit blanc.

Propriété 1

Soit $(X_t)_{t\in\mathbb{Z}}$ un processus stationnaire au second ordre et $(a_i)_{i\in\mathbb{Z}}$ tel que $\sum_{i=-\infty}^{+\infty} |a_i| < +\infty$ (i.e. les $(a_i)_{i\in\mathbb{Z}}$ sont supposés sommables)

$$alors \;\; y_t = \sum_{i\in\mathbb{Z}} a_i X_{t-i} \;\; \textit{est un processus stationnaire}$$

La stationnarité assure que le modèle puisse être utiliser en dehors de la période sur laquelle il a été estimé.

Exemples

`Situation 1`

$(X_t)_{t\in\mathbb{Z}}$ est stationnaire en moyenne
$(X_t)_{t\in\mathbb{Z}}$ est stationnaire en variance
$\Rightarrow$ le modèle linéaire s'applique, (ARMA par exemple).

`Situation 2`

$(X_t)_{t\in\mathbb{Z}}$ est stationnaire en moyenne et non stationnaire en variance (non-station1naire de type stochastique)
$\Rightarrow$ le modèle non linéaire s'applique, (ARCH par exemple).

`Situation 3`

$(X_t)_{t\in\mathbb{Z}}$ est non stationnaire en moyenne et stationnaire en variance (non-stationnaire de type déterministe)
$\Rightarrow$ le modèle non linéaire s'applique, (MARKOV par exemple).

Remarque
La notion de stationnarité stricte et de stationnarité au second ordre se confondent pour les processus Gaussiens car ceux-ci sont entièrement résumés par leurs deux premiers moments (car pour un processus gaussien, les moments d'ordre supérieurs à 2 sont automatiquement nuls et pour tout $n \in \{1, 2, ...\}$ et pour tout $h, t_1, ..., t_n \in \mathbb{Z}$, les vecteurs aléatoirs $(X_{t_1}, ..., X_{t_n})'$ et $(X_{t_1+h}, ..., X_{t_n+h})'$ ont la même moyenne et matrice de covariance et donc la même distribution). Par contre dès que l'on sort du cadre Gaussien comme dans les modèles GARCH, on n'a plus coincidence entre les deux notions.

1.1.3 Ergodicité

Un processus stationnaire est dit ***ergodique*** si l'on peut calculer l'ensemble de ses caractéristiques (moyenne, variance, fonction d'autocorrélation) à partir d'une seule trajectoire du processus, c'est-à-dire à partir d'une observation du processus et, par conséquent, de façon pratique, à partir de la série temporelle observée suffisamment longtemps. Ainsi, pour un processus stationnaire, ***l'hypothèse d'ergodicité*** pose l'équivalence entre moyenne d'ensemble (espérance mathématique) et moyenne temporelle (ou spatiale) sur un domaine "infini", soit

$$\mu_X = E(X_t) = \lim_{T \to \infty} \frac{1}{T} \sum_{t=1}^{T} X_t.$$

l'espérance du processus est la limite de la moyenne des valeurs des observations de la série quand la durée d'observation tend vers l'infini.

Ainsi, on dit qu'une suite stationnaire est ***ergodique*** si elle satisfait la loi forte des grands nombres.

1.1.4 Théorème de Wold (1954)

Ce théorème est à la base de la modélisation des séries temporelles stationnaires. Il montre que tout processus stationnaire peut être représenté de manière unique par la somme de deux composantes indépendantes, une composante régulière parfaitement prévisible parfois appelée déterministe et une composante stochastique :

Théorème 2
Si $(X_t)_{t \in \mathbb{Z}}$ est un processu stationnaire alors X_t peut se décomposer de la manière suivante :

$$X_t = d_t + u_t \quad \text{où} \quad \begin{cases} d_t & \textit{est la partie déterministe} \\ \textit{et} & \\ u_t & \textit{est la partie aléatoire.} \end{cases}$$

C'est la partie aléatoire qui nous permet de savoir la loi de X_t. La partie aléatoire $(u_t)_{t \in \mathbb{Z}}$ peut s'écrire sous la forme suivante :

$$u_t = \sum_{i=0}^{\infty} a_i \varepsilon_{t-i}$$

où $\sum_{i=0}^{\infty} a_i^2 < +\infty$ et où $(\varepsilon_t)_{t \in \mathbb{Z}}$ est un bruit blanc de moyenne nulle et de variance finie.
Cette forme de la composante stochastique est appellée processus moyenne mobile infinie. Un des buts de la modélisation consiste à approximer cette moyenne mobile infinie par un processus ayant un nombre fini de paramètres. Ce sera le cas avec les processus AR, MA et ARMA.

Remarque
Si la partie déterministe est dominante par rapport à la partie stochastique, on dira que la série est `fortement prévisible`. C'est le cas, par exemple, de la série du nombre de taches solaires, cette série étant quasiment sinusoïdale. Dans le cas contraire, on dira que la série temporelle étudiée est `fortement aléatoire`. C'est le cas des séries financière comme les indices boursiers car ces séries sont influencées par des évènement extérieurs très aléatoire eux-même, par exemple les tristement célèbres évènements du 11 septembre 2001.

1.1.5 Bruit Blanc

Le processus le plus simple mais véritable atome de base de tous nos modèles est le processus dit "bruit blanc", (white noise) White (1982).

Définition 3
Un processus $(\varepsilon_t)_{t\in\mathbb{Z}}$ est dit de bruit blanc (faible) (noté BB) si

1. $E(\varepsilon_t) = 0, \quad \forall\ t$
2. $Var(\varepsilon_t) < \infty, \quad \forall\ t \qquad (ou \quad Var(\varepsilon_t) = \sigma_\varepsilon^2 \ \ \forall\ t)$
3. $Cov(\varepsilon_t, \varepsilon_{t+h}) = 0 \quad \forall\ h \geq 1$

Un bruit blanc est ainsi un processus de moyenne nulle, de variance constante et non auto-corrélé.

$$\text{On note} \quad \varepsilon_t \sim BB(0, \sigma_\varepsilon^2).$$

On dit qu'il est **fort** lorsque de plus les variables ε_t sont indépendantes et que les moments d'ordre 2 existent.
On appelle **bruit blanc gaussien** tout bruit blanc fort $(\varepsilon_t)_{t\in\mathbb{Z}}$ tel que $\forall\ t, \varepsilon_t \sim \mathcal{N}(0, \sigma^2)$.

Remarque :
Un bruit blanc n'est pas nécessairement gaussien.
Si $(\varepsilon_t)_{t\in\mathbb{Z}}$ est un bruit blanc gaussien alors les variables ε_t sont indépendantes.
Le brui blanc $(\varepsilon_t)_{t\in\mathbb{Z}}$ est un processus sans mémoire car la variable aléatoire ε_t est non corrélée aux variables aléatoires précédentes $\varepsilon_{t-1}, \varepsilon_{t-2}, ...$

Sous R, la trajectoire du bruit blanc $BBG(0,1)$ et celle du bruit blanc uniforme $BBU_{[-1,1]}$, de longueur n, sont simulées par les commandes ci-dessous.

```
eps<-rnorm(n, mean=0, sd=1)
eps<-runif(n, -1, 1)
```

1.1.6 Processus d'innovation

Définition 4
Le processus d'innovation $(\varepsilon_t)_{t\in\mathbb{Z}}$ d'un processus $(X_t)_{t\in Z}$ est défini comme étant l'écart entre la variable X_t au temps t et sa projection sur l'espace vectoriel engendré par les variables jusqu'au temps $t-1$, i.e. :

$$\varepsilon_t = X_t - E(X_t|I_{t-1})$$

c'est-à-dire

$$\varepsilon_t = X_t - X_t^*$$

où X_t^* est la régression affine de X_t sur $(X_s, s < t)$. C'est la meilleure approximation affine de X_t fonction de son passé. L'innovation est alors la partie de X_t non corrélée au passé de la série :

$$X_t = d_t + \varepsilon_t$$

La partie aléatoire ε_t est la partie de X_t non corrélée avec $(X_{t-s}, s > 0)$; cette partie représente l'innovation de X_t.

On montre que le processus d'innovation d'un processus stationnaire est un bruit blanc et qu'un processus bruit blanc est son propre processus d'innovation.

1.2 Analyse temporelle

1.2.1 Moyenne et Variance

Sous l'hypothèse de la stationnarité, la moyenne $\mu = E(X_t)$ définie le niveau à travers lequel la série fluctue (change) et la variance $\sigma_X^2 = V(X_t) = E(X_t - \mu)^2$ mesure la dispersion ou la variation de la série autour de la moyenne.
On considère une série temporelle X_t, $t = 1, ..., n$ issue d'un processus $(X_t)_{t\in\mathbb{Z}}$, on estime la moyenne et la variance du processus $(E(X_t), V(X_t))$ à l'aide de la moyenne empirique et de la variance empirique de la série, définies respectivement par

$$\overline{X} = \frac{1}{n}\sum_{t=1}^{n} X_t, \qquad \hat{\sigma}^2 = \frac{1}{n}\sum_{t=1}^{n}(X_t - \overline{X})^2$$

Sous **R**, la moyenne et la variance d'une série, parexemple nommée `maserie`, sont obtenues par les commandes suivantes :

```
mean(maserie)
var(maserie)
```

1.2.2 Fonction d'autocovariance

La fonction d'autocovariance au retard h, noté $\gamma(t, h)$, d'un processus $(X_t)_{t\in\mathbb{Z}}$ mesure la covariance entre ses valeurs distantes de h unités de temps. Elle est définie, pout tout $t \in \mathbb{Z}$ et $h \in \mathbb{Z}$, par :

$$\begin{aligned} \gamma(t,h) &= Cov(X_t, X_{t-h}) \quad t, h \in \mathbb{Z} \\ &= E\big[\big(X_t - E(X_t)\big)\big(X_{t-h} - E(X_{t-h})\big)\big] \end{aligned}$$

- Si le processus est stationnaire $\gamma(t, h) = \gamma(h)$ i.e. les autocovariances ne sont pas fonction de la variable temps t.

- Elle est estimée par la fonction d'autocovariance empirique, $\hat{\gamma}(.)$, définie, pour $0 \leq h < n$, par :

$$\hat{\gamma}(h) = \frac{1}{n}\sum_{t=1}^{n-h}(X_t - \overline{X}_n)(X_{t-h} - \overline{X}_n)$$

Théorème 5
La fonction d'autocovariance d'un processus X_t stationnaire vérifie les propriètés suivantes :

1. $\gamma_0 = Cov(X_t, X_t) = V(X_t) = \sigma_{X_t}^2 \geq 0$
2. $|\gamma(h)| \leq \gamma_0 \quad \forall\ h \geq 0$
3. $\gamma(h) = \gamma(-h) \quad \forall h$

Exercice 1
On considère

$$X_t = \varepsilon_t - \varepsilon_{t-1}$$

où (ε_t) est un processus stationnaire de moyenne nulle et de variance σ^2 et telle que $Cov(\varepsilon_t, \varepsilon_s) = 0$ si $t \neq s$.

1. Calculer la moyenne et la variance de (X_t).
2. Calculer la fonction d'autocovariance $\gamma(h)$ $\forall$ $h \geq 0$.

Exercice 2
Soit $(X_t)_{t\in\mathbb{Z}}$ un processus stationnaire tel que

$$X_t = 0,4X_{t-1} + \varepsilon_t$$

où $\varepsilon_t \sim BB(0, \sigma^2)$ et $Cov(\varepsilon_t, X_{t-s}) = 0,\ s > 0$.

1. Calculer la moyenne et la variance de (X_t).
2. Calculer la fonction d'autocovariance $\gamma(h) \quad \forall\ h$.

1.2.3 Fonction d'autocorrélation (ACF) et fonction d'autocorrélation partielle (PACF)

La notion d'autocorrélation découle de la notion d'autocovariance comme la corrélation de la covariance.
On appelle autocorrélation (ou serial correlation) la corrélation d'une série chronologique avec ses valeurs passées.

– **Fonction d'autocorrélation (ACF)**
Soit $(X_t)_{t\in\mathbb{Z}}$ un processus stationnaire. La fonction d'autocorrélation de $(X_t)_{t\in\mathbb{Z}}$, que l'on note ACF (AutoCorrelation Function), au retard h, notée, $\rho(h)$ est donnée, pour tout $t \in \mathbb{Z}$ et $h \in \mathbb{Z}$ par :

$$\rho(h) = \frac{\gamma(h)}{\sigma_{X_t}\sigma_{X_{t+h}}} = \frac{\gamma(h)}{\gamma(0)}$$

Elle est estimée par la fonction d'autocorrélation empirique, $\hat{\rho}(.)$, définie, pour $0 \leq h < n$, par :

$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}_0}$$

La fonction d'autocorrélation permet de mesurer les liaisons temporelles entre les différentes composantes de la série X_t. Ainsi le nombre $\rho(h) \in [-1, 1]$ mesure la corrélation linéaire entre les variables X_t et X_{t+h} et $\rho(0) = 1$.

Exemple
On considère le même Exercice 1.

3. Calculer la fonction d'autocorrélation $\rho(h)$ $\forall$ $h \geq 0$.

– **Fonction d'autocorrélation partielle (PACF)**
L'idée de la corrélation partielle est de mesurer le degré de liaison entre 2 variables en neutralisant (ou en contrôlant) les effets d'une ou d'autres variables.
Considérons le processus $(X_t)_{t\in\mathbb{Z}}$ aux instants $t-h, ..., t$. La fonction d'autocorrélation partielle mesure la corrélation entre X_t et X_{t-h}, l'influence des variables intermédiaires étant

supposée retirer, c'est à dire lorsqu'on a éliminé les parties de X_t et X_{t-h} expliquées par les variables intermédiaires. (i.e les variables X_{t-h+i} telle que $(i < h)$).
La fonction d'autocorrélation partielle au retard h, notée, $r(h)$ est donnée, pour tout $t \in \mathbb{Z}$ et $h \in \mathbb{Z}$ par :

$$\begin{aligned} r(h) &= corr(X_t - X_t^*, X_{t-h} - X_{t-h}^*) \\ &= \frac{cov(X_t - X_t^*, X_{t-h} - X_{t-h}^*)}{\sqrt{var(X_t - X_t^*)var(X_{t-h} - X_{t-h}^*)}} , \end{aligned}$$

avec

$$r(1) = \rho(1)$$

et où, pour tout t, X_t^* est la regression affine de X_t sur $X_{t-1}, X_{t-2}, ..., X_{t-h+1}$ ou projection orthogonale de X_t sur le sous espace vectoriel de L^2 engendré par $X_{t-1}, X_{t-2}, ..., X_{t-h+1}$ et X_{t-h}^* est la regression affine de X_{t-h} sur $X_{t-h+1}, X_{t-h+2}, ..., X_{t-1}$.

$$X_t^* = \alpha_1 X_{t-1} + \alpha_2 X_{t-2} + ... + \alpha_{h-1} X_{t-h+1}$$

$$X_{t-h}^* = \alpha_{h-1} X_{t-h+1} + \alpha_{h-2} X_{t-h+2} + ... + \alpha_1 X_{t-1}$$

Les coefficients, $\alpha_1, ..., \alpha_{h-1}$ sont les mêmes.

Définition 6
on appelle fonction d'autocorrélation partielle d'un processus stationnaire $(X_t)_{t\in\mathbb{Z}}$, la fonction $r(.)$ est définie, pour tout $h \in \mathbb{Z}^*$, par

$$r(h) = \phi_{h,h} \quad et \quad r(0) = 1$$

Pour un retard h fixé, le nombre $r(h)$ est alors le coefficient de corrélation linéaire entre la variable $X_t - E(X_t|X_{t+1}, X_{t+2}, ..., X_{t+h-1})$ et la variable $X_{t+h} - E(X_{t+h}|X_{t+1}, X_{t+2}, ..., X_{t+h-1})$.
$X_t - E(X_t|X_{t-1}, X_{t-2}, ..., X_{t-h+1})$ et la variable $X_{t-h} - E(X_{t-h}|X_{t-h+1}, X_{t-h+2}, ..., X_{t-1})$.

Par construction, on a : $r(1) = \rho(1)$ et est également à valeurs dans $[-1, 1]$.

Theorem 1.1
Soit $(X_t)_{t\in\mathbb{Z}}$ un processus stationnaire. On considère la regression linéaire de X_t sur $X_{t-1}, ..., X_{t-h}$:

$$\mathbb{EL}(X_t|X_{t-1}, ..., X_{t-h}) = \sum_{j=1}^{h} \phi_{h,j} X_{t-j}$$

et

$$\varepsilon_t = X_t - \mathbb{EL}(X_t|X_{t-1}, ..., X_{t-h})$$

Alors on a
– $E(\varepsilon_t) = 0$ et il existe $\sigma > 0$ tel que pour tout $t \in \mathbb{Z}$, $\mathbb{E}(\varepsilon_t^2) = \sigma^2$
– $\forall\ i \in \{1, ..., h\} : E(\varepsilon_t X_{t-i}) = 0$
Et on a $\phi_{hh} = r(h)$ ainsi que

$$\begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_h \end{pmatrix} = R_h \begin{pmatrix} \phi_{h1} \\ \phi_{h2} \\ \vdots \\ \phi_{hh} \end{pmatrix}$$

où R_h est la matrice d'autocorrélation de $(X_t, ..., X_{t-h+1})$, $h \in \mathbb{N}^*$ est définie comme suit :

$$R_h = \begin{pmatrix} 1 & \rho_1 & \rho_2 & \dots & \dots & \rho_{h-1} \\ \rho_1 & 1 & \rho_2 & \dots & \dots & \rho_{h-2} \\ \rho_2 & \rho_2 & \ddots & \dots & \dots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ \vdots & \vdots & \vdots & \dots & \ddots & \rho_1 \\ \rho_{h-1} & \rho_{h-2} & \dots & \dots & \rho_1 & 1 \end{pmatrix}$$

En inversant la matrice R_h, on estime alors les $\phi_{hi}, i = 1, ..., h$.

Les coefficients ϕ_{hh} peuvent être estimés en se servant de la méthode des moindre carrés ordinaires.

Une méthode plus rapide d'estimer les coefficients d'autocorrélation partielles $r(h)$ ou ϕ_{hh}, pour tout h est d'utiliser la relation de recurrence suivante, appelée algorithme de Durbin-Levinson (1960) :

$$\begin{cases} \phi_{1,1} = \rho_1 \\ \phi_{h,h} = \frac{\rho_h - \sum_{j=1}^{h-1} \phi_{h-1,j}\rho_{h-j}}{1 - \sum_{j=1}^{h-1} \phi_{h-1,j}\rho_j} \quad pour \quad h = 2, 3... \\ \phi_{h,j} = \phi_{h-1,j} - \phi_{h,h}\phi_{h-1,h-j} \quad pour \ h = 2, 3, ... \ et \ j = 1, ..., h-1 \end{cases}$$

Le coefficient d'autocorrélation partielle d'ordre h traduit une corrélation conditionnelle entre la série initiale (X_t) et celle retardée de h relevés, soit (X_{t-h}). Le conditionnement correspond à la corrélation non expliquée par les relevés intermédiaires $(X_{t-1}, X_{t-2}, ..., X_{t-h-1})$. Le corrélogramme partiel sert donc à détecter des effets qui ne dépendent pas linéairement des relevés à petite distance (en temps).

Mise en oeuvre :
On considère la série de donnée nommée `maserie`, de taille n, on obtient les graphiques de l'ACF et du PACF, par les commandes suivantes :
`acf(maserie, lag.max=100)` // permet d'obtenir l'ACF.
`acf(maserie, lag.max=100, type="partial")` // permet d'obtenir le PACF.

1.3 Outils d'analyse spectrale

L'analyse spectrale a plusieurs application dans le domaine des séries chronologiques, une application intéressante est celle de l'indentification des cycles dans les données.

1.3.1 Densité Spectrale

La densité spectrale ou spectre est la répartition de la dispersion, plus précisément de la variance, en fonction des fréquences. Elle est l'analogue, dans le domaine des fréquences, de la fonction d'autocovariance dans la domaine temporel.
L'interêt de la densité spectrale est de mettre en évidence surtout les phénomènes cycliques dans les données. Pour les données saisonnières avec une saison s, la densité spectrale a un pic dominant à la fréquence de Fourier $\lambda_j = \frac{js}{T}$ où T est la taille de l'échantillon, le cycle correspondant est donné par $cycle = \frac{T}{j}$.

Exemple : Considérons la série de trafic passagers de l'ensemble de la banlieue de la RATP. Avec les codes : *trafic<-read.table("trafic.txt", sep="", header=T)* et *spec.pgram(trafic)* on obtient, la représentation suivante :

FIG. Densité spectrale de la série du trafic passagers de la RATP.

On remarque que le pic dominant est à la fréquence $\lambda_j = 1$ or $\lambda_j = \frac{js}{T}$ donc $j = \frac{T}{s}$ et $cycle = \frac{T}{T/s} = s = 12$.

La densité spectrale permet aussi de mettre en évidence la nature de la mémoire des séries. En effet, la présence d'un pic quand les fréquences tendent vers 0 sera interprétée comme présence de longue mémoire.
Elle est utilisée surtout en traitement du signale.

Définition 7
Soit $(X_t)_{t\in\mathbb{Z}}$, un processus stationnaire , de fonction d'autocovariance $\gamma(.)$, définie ci-dessus. La densité spectrale de $(X_t)_{t\in\mathbb{Z}}$ est la fonction $f(.)$ définie comme étant la transformée de Fourier de la fonction d'autocovariance du processus :

$$f(\lambda) = \frac{1}{2\pi} \sum_{h=-\infty}^{+\infty} \gamma(h) e^{-i\lambda h}, \quad \forall\ \lambda \in [-\pi, \pi], \quad h \in \mathbb{Z}$$

En utilisant la parité de la fonction d'autocovariance, on voit que la densité est une fonction réelle, et on a

$$f(\lambda) = \frac{1}{2\pi} \sum_{h=-\infty}^{+\infty} \gamma(h) \cos(\lambda h), \quad \forall\ \lambda \in [-\pi, \pi], \quad h \in \mathbb{Z}$$

En pratique on travaille plûtot sur la densité spectrale normé, qui est la transformée de Fourier de la fonction des corrélations (théoriques) :

$$f(\lambda) = \frac{1}{2\pi} \sum_{h=-\infty}^{+\infty} \rho(h) e^{-i\lambda h}, \quad \forall\ \lambda \in [-\pi, \pi]$$

Remarque
La densité spectrale est une fonction paire, positive, continue et périodique de période 2π. On peut alors raisonner sur l'inetrvalle continu $[-\pi, \pi], [0, 2\pi]$ ou plus généralement $\lambda = \pm 2\pi n$ pour $n \in \mathbb{R}$, par exemple pour des observations mensuelles, la période est l'année : $T = 12$ mois et la fréquence angulaire est : $\lambda = \frac{2\pi}{T} = \frac{\pi}{6}$.

A partir de la densité spectrale, la transformation inverse de Fourier permet de retrouver la fonction d'autocovariance $\gamma(h)$, ainsi on a :

$$\gamma(h) = \int_{-\pi}^{\pi} f(\lambda) cos(\lambda h) d\lambda = \int_{-\pi}^{\pi} f(\lambda) e^{i\lambda h} d\lambda$$

Posons $\lambda_j = \frac{2\pi j}{n}, \quad j = 0, ..., n$

$$\text{on a : } \quad \gamma(h) = \frac{1}{2\pi} \sum_{j=0}^{n} f(\lambda_j) e^{i\lambda_j h} \quad \text{cas discrétisé}$$

Si on considère la trajectoire finie $X_1, ..., X_n$, issue du processus stationnaire $(X_t)_{t\in\mathbb{Z}}$, alors la densité théorique du processus est estimée par la fonction, noté $I_n(.)$ calculée sur la série $X_1, ..., X_n$ définie, pour tout $\lambda \in [-\pi, \pi]$, par

$$I_n(\lambda) = \frac{1}{2\pi n} \left| \sum_{t=1}^{n} (X_t - \overline{X}_n) e^{-i\lambda t} \right|^2$$

On l'appelle le **périodogramme**.

Proposition 1.2
Si les fréquences de Fourier λ_j sont non nulles pour tout j alors

$$I_n(\lambda_j) = \frac{1}{2\pi} \sum_{h=-n}^{n} \hat{\gamma}(h) e^{-i\lambda_j h}$$

On a aussi

$$\begin{aligned} I_n(\lambda) &= \frac{1}{2\pi} \sum_{h=-n}^{n} \hat{\gamma}(h) cos(\lambda h)\Big) \\ &= \frac{1}{2\pi} \Big(\hat{\gamma}(0) + 2 \sum_{h=1}^{n} \hat{\gamma}(h) cos(\lambda h) \Big) \end{aligned}$$

Cet estimateur de la densité spectrale du processus $(X_t)_{t\in\mathbb{Z}}$ est sans biais, mais non consistant. Pour l'estimation sous S-Plus et R, on utilise
`periodog(maserie)` ou **periodogram(maserie)** .
pic<—**periodogram(maserie)**,
pic$fraq #renvoie les fréquences de Fourier,
pic$spec #montre le pic dominant.

On peut améliorer cet estimateur, en utilisant une fonction de pondération.

En effet une expression du **périodogramme lissé** est donnée par

$$I_n^L(\lambda_j) = \frac{1}{2\pi} \sum_{h=-m}^{m} w_n(h) I_n(\lambda_j + h),$$

où, pour $j = 0, ..., n-1$, $I_n(\lambda_j)$ est le périodogramme pour la fréqence de Fourier λ_j, où m est un entier positif ou nul qui contrôle la longueur de la moyenne mobile et où $(w_n(h))_h$ est une suite de poids dont les valeurs sont telles que :

$$w_n(h) = \begin{cases} \frac{1}{2m} & \text{pour } h = -m+1, ..., -1, 0, 1, ..., m-1, \\ \frac{1}{2\times 2m} & \text{pour } h = -m, m. \end{cases}$$

Pour l'estimation de la densité sous S-Plus et R, on utilise
`spectrum(maserie)` // estime le periodogramme par méthode de lissage

La densité spectrale d'un bruit blanc de variance σ^2 est donnée par :

$$\begin{aligned} f(\lambda) &= \frac{1}{2\pi}\sum_{h=-\infty}^{+\infty}\gamma(h)e^{i\lambda h} \\ &= \frac{\gamma(0)}{2\pi} = \frac{\sigma^2}{2\pi}(= cste) \end{aligned}$$

car

$$\gamma(h) = \begin{cases} \sigma^2 & pour\ h = 0 \\ 0, & pour\ h \neq 0 \end{cases}$$

est la fonction d'autocorrélation du bruit.
Inversement, si la densité spectrale d'une série stationnaire (X_t), est constante : $f(\lambda) = c$, alors (X_t) est un bruit blanc.
En effet

$$\gamma(h) = \int_{-\pi}^{+\pi} f(\lambda)\cos(\lambda h)d\lambda = c\int_{-\pi}^{+\pi}\cos(\lambda h)d\lambda = 0, \quad si\ h \neq 0$$

Cette nullité de la fonction d'autocorrélation, pour tout $h \neq 0$, est donc une caractéristique du bruit blanc.

1.3.2 Corrélogramme

C'est la représentation graphique de la fonction d'autocorrélation. Du fait de la parité de cette dernière, la représentation est restreinte aux h positifs. Il est très utile pour repérer le type de modèle auquel correspond la série (marche aléatoire(AR(1)), AR(2), BB,...).
Il permet aussi de voir si la série est stationnaire.

Exemple de corrélogrammes

Fig. 1 : Corrélogramme d'une série stationnaire.
La corrélation diminue très rapidement au fur et à mesure que le temps passe.

Fig. 2 : Corrélogramme d'une série non stationnaire.
La corrélation diminue mais reste élevée au fur et à mesure que le temps passe.

2 Les processus linéaires de types ARMA

Nous nous intéressons, dans cette partie à l'étude d'une famille de processus linéaires stationnaires. Ces processus comme nous le verrons, sont très généraux. Ils présentent une modélisation estimable, opérationnelle pour les séries économiques.
Nous allons nous intéresser au cas où la série de données à modéliser (une fois la tendance déterministe retranchée) présente une certaine homogénéité au cours du temps. On fait l'hypothèse que la variance des variables aléatoires reste constante et que les relations de dépendance entre variables successives sont les mêmes au cours du temps.

2.1 Processus linéaire

Définition 8
Un processus $(X_t)_{t\in\mathbb{Z}}$ est dit processus linéaire s'il admet une décomposition de la forme suivante,

$$X_t = \sum_{j=-\infty}^{+\infty} a_j \varepsilon_{t-j}, \qquad t \in \mathbb{Z} \tag{1}$$

où $(a_t)_{t\in\mathbb{Z}}$ est une suite de nombre réels absolument sommable, c'est à dire $\sum_{j=-\infty}^{+\infty} |a_j| < \infty$ et ε_t un processus d'innovation.

L'observation X_t est une combinaison linéaire de ses valeurs du passé et des innovations ε_t (shocks purement aléatoires).

Exemple

$$X_t = \varepsilon_t - \theta\varepsilon_{t-1}$$

Pour que (1) s'interprète correctement il faut que $(X_t)_{t\in\mathbb{Z}}$ soit inversible, c'est à dire que l'on ait aussi

$$\varepsilon_t = \sum_{j=-\infty}^{+\infty} b_j X_{t-j} \quad \text{avec} \begin{cases} b_0 = 1 \\ et \\ \sum_{j=0}^{+\infty} |b_j| < \infty \end{cases} \tag{2}$$

Dans la pratique on se ramène à un modèle paramétrique en considérant les décomposition

$$X_t = \sum_{j=0}^{q} a_j \varepsilon_{t-j}, \qquad t \in \mathbb{Z} \tag{3}$$

ou

$$\varepsilon_t = \sum_{j=0}^{p} b_j X_{t-j}, \qquad t \in \mathbb{Z} \tag{4}$$

Les processus associés s'appellent respectivement processus *moyenne mobile* d'ordre q (MA(q)) et processus *autorégressif* d'ordre p (AR(p)).

Proposition 2.1
Si (X_t) est un processus linéaire défini par (1) avec $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$, alors (X_t) est stationnaire et on a :

$$\gamma_0 = V(X_t) = \sigma_\varepsilon^2 \sum_{j=-\infty}^{+\infty} a_j^2$$

et

$$\gamma(h) = \sigma_\varepsilon^2 \sum_{j=-\infty}^{+\infty} a_j a_{j+h} \quad \forall\ h \in \mathbb{Z}$$

2.2 Opérateur retard

L'opérateur retard, noté L (Lag) ou B (Backward) suivant les ouvrages, est défini de la façon suivante :

Définition 9
On considère un processus stochastique $(X_t)_{t\in\mathbb{Z}}$, l'opérateur retard noté B est défini par la relation :

$$BX_t = X_{t-1}, \quad t \in \mathbb{Z}$$

Plus généralement, on a

$$B^n X_t = X_{t-n}, \quad \forall\, n \in \mathbb{N}$$

On remarque que l'opérateur retard transforme une variable X_t en sa valeur passée.
L'opérateur retard est linéaire et inversible. Son inverse $B^{-1} = F$ est défini par :

$$B^{-1}X_t = FX_t = X_{t+1}$$

$$F^n X_t = X_{t+n}, \quad \forall\, n \in \mathbb{N}$$

L'opérateur F est appelée opérateur avancé.

Propriété 10
L'opérateur retard vérifie les propriétés suivantes :
- $B^n X_t = X_{t-n} \quad \forall n \in \mathbb{Z}$
  $B^n X_t = B^{n-1} B X_t$
  $\qquad\quad = B^{n-1} X_{t-1}$
  en particulier $\quad B^0 X_t = X_t$
- $B^{-n} X_t = X_{t+n}$
- $(B^n + B^m)X_t = B^n X_t + B^m X_t = X_{t-n} + X_{t-m} \quad \forall\, (n,m) \in \mathbb{Z}^2$
- *Si* $\quad X_t = c, \quad \forall\, t \in \mathbb{Z} \quad$ *avec* $\quad c \in \mathbb{R}, \quad B^n X_t = B^n c = c, \quad \forall\, n \in \mathbb{Z}$
- $B^n(B^m X_t) = B^{n+m} X_t = X_{t-n-m}, \quad \forall\, (n,m) \in \mathbb{Z}^2$
  en effet $\; B^n(B^m X_t) = B^n(X_{t-m}) = X_{t-m-n}$

On peut ainsi écrire un polynôme à l'aide de l'opérateur retard :

$$\sum_{k=0}^{p} a_k X_{t-k} = \Big(\sum_{k=0}^{p} a_k B^k\Big) X_t$$

De même, on définit l'opérateur avance, noté F (Forward) par :

$$FX_t = X_{t+1}, \quad t \in \mathbb{Z}$$

On a : $\forall t \in \mathbb{Z}, \quad FBX_t = BX_{t+1} = X_t \quad$ et $\quad BFX_t = FX_{t-1} = X_t$.
Par conséquent, F et B sont des opérateurs inverses l'un de l'autre pour la composition : $F = B^{-1} \Longleftrightarrow B = F^{-1}$.

Remarque
L'opérateur retard est en particulier très utile pour écrire de façon compacte les processus ARMA que nous allons étudiés dans la suite.

2.3 Modèles simples : AR et MA

2.3.1 Processus Autoregressifs (Processus AR)

Ils ont été introduit par Yule en 1927. On prend en compte une dépendance linéaire du processus à son passé.

Définition 11
On appelle ***processus autorégressif*** *d'ordre p tout processus stationnaire* $(X_t)_{t\in\mathbb{Z}}$ *tel que*

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + ... + \phi_p X_{t-p} + \varepsilon_t \quad où \quad (\phi_i)_{i=1,...,p} \in \mathbb{R}^p \ et \ \phi_p \neq 0$$

$(\varepsilon_t)_{t\in Z}$ *est un bruit blanc,* $\varepsilon_t \sim BB(0, \sigma^2)$.

Que l'on peut écrire sous forme condensée par l'équation suivante

$$\Phi(B)X_t = \varepsilon_t \tag{5}$$

$\Phi(.)$ *est appelé polynôme autorégressif d'ordre p.*

On parle ici de représentation autorégressive, dans le sens où la variable X_t *est déterminée par les valeurs du passé* $X_{t-1}, ..., X_{t-p}$. *Le nombre de retards utilisés (ici p) s'appelle l'ordre de l'autorégression.*

Si les racines du polynôme Φ sont à l'extérieur du disque unité, on dit que la représentation $\Phi(B)X_t = \varepsilon_t$ est la `représentation canonique` de X_t.

Remarque
Si toutes les racines du polynôme Φ sont en dehors du cercle unité (i.e. si $\Phi(z)$ n'a pa de racine de module inférieure ou égale à 1), c'est à dire $\Phi(z) \neq 0, \forall z \in \mathbb{C}$ tel que $|z| \leq 1$ alors on peut inverser l'opérateur $\Phi(B)$ défini sur les valeurs du processus stationnaire. On en déduit que l'équation (5) admet une solution unique et $(X_t)_{t\in\mathbb{Z}}$ peut se réécrire sous la forme moyenne mobile infinie $(MA(+\infty))$:

$$X_t = \Phi^{-1}(B)\varepsilon_t = \sum_{j=0}^{+\infty} \alpha_j \varepsilon_{t-j} \quad \text{où} \quad \begin{cases} \alpha_0 = 1 \\ et \\ \sum_{j=0}^{+\infty} |\alpha_j| < \infty \end{cases}$$

Et $(X_t)_{t\in\mathbb{Z}}$ est dit dans ce cas **causal** ou **stationnaire**, ε_t est le processus d'innovation de X_t, puisque le passé de X_t dépend du passé de ε_t.

Définition 12
Un processus $(X_t)_{t\in\mathbb{Z}}$ *est dit* ***causal*** *lorsqu'il existe une suite de nombres* (α_k) *telle que* $\sum_{k\in\mathbb{Z}} |\alpha_k| < \infty$ *et*

$$X_t = \sum_{k=0}^{\infty} \alpha_k \varepsilon_{t-k}$$

Ainsi, un processus causal peut être déterminé à partir de la connaissance des valeurs prises jusqu'à l'instant t par une autre variable, relation ici entre X_t *et* ε_t.

Remarquons immédiatement que tout processus à *moyenne mobile* est, par définition, ***causal***.

Théorème 13
Un processus $AR(p)$ est dit ***causal*** *si toutes les racines du polynôme Φ sont en dehors du cercle unité.*

Causalité
Au sens des séries temporelles X_t est **causal** signifie que la prévision de X_t basée sur la connaissance des passés conjointes de ε_t et de X_t est meilleure que celle de X_t fondée sur la seule connaissance du passé de X_t.

Causalité au sens de Sims (1980)
X_t est causal si les valeurs futures de X_t peuvent expliquer les valeurs présentes de ε_t, et on dira que ε_t est la cause de X_t (ou ε_t cause X_t). On peut aussi dire que X_t est causale si les innovations **de** ε_t contribuent à la variance de l'erreur de prévision de X_t.

Fonction d'autocorrélation
Pour calculer la fonction d'autocorrélation on passe par la fonction d'autocovariance.
Soit $\gamma(.)$ la fonction d'autocovariance du processus $(X_t)_{t\in\mathbb{Z}}$, on a :

$$\gamma(h) = E(X_t X_{t-h}) = ?$$

Après calcul, on trouve

$$\gamma(h) = \begin{cases} \displaystyle\sum_{i=1}^{p} \phi_i \gamma(h-i) & \forall\ h > 0 \\ \displaystyle\sum_{i=1}^{p} \phi_i \gamma(i) & \text{si} \quad h = 0 \end{cases}$$

$$Or \quad \forall \quad h \qquad \rho(h) = \frac{\gamma(h)}{\gamma_0}$$

donc la fonction d'autocorrélation d'un processus $AR(p)$ est donnée par

$$\rho(h) = \begin{cases} \displaystyle\sum_{i=1}^{p} \phi_i \rho(h-i) & \forall\ h > 0 \\ 1 \quad \text{si} & h = 0 \end{cases}$$

Equation de Yule Walker

Remarque

$$Si \quad \sum_{i=1}^{p} \phi_i \rho(h-i) = 1 \ \text{ le processus est non stationnaire}$$

Fonction d'autocorrélation partielle (PACF) d'un processus AR(p)
L'algorithme de Durbin (1960) permet de trouver une expression de la PACF d'un processus AR(p).
Ces coefficients sont donnés par la formule récursive suivante :

$$PACF : \begin{cases} \phi_{1,1} = \rho(1) \\ \phi_{h,h} = \frac{\rho(h) - \sum_{j=1}^{h-1} \phi_{h-1,j}\rho(h-j)}{1 - \sum_{j=1}^{h-1} \phi_{h-1,j}\rho(j)}, \quad h = 2, 3, ... \\ \phi_{h,j} = \phi_{h-1,j} - \phi_{h,h}\phi_{h-1,h-j} \quad h = 2, 3, ... \ ; \quad j = 1, ..., h-1 \end{cases}$$

Propriété 14
Pour un processus AR(p) alors $\phi_{h,h} = 0 \ \forall h > p$. Celà veut dire que les autocorrélations partielles s'annulent à partir du retard $p+1$.

Exemple
$X_t = 0.4X_{t-1} + \varepsilon_t$ où $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$ *et* $Cov(\varepsilon_t, X_{t-s}) = 0 \ \ s > 0$

1. Ce processus est-il causal ?
2. Calculer la fonction d'autocorrélation partielle du processus.

Le logiciel R permet de simuler des trajectoires finies engendrées par un processus AR. Par exemple, on s'intéresse au processus centré AR(2), tel que :

$$(I - 0.4B - 0.2B^2)X_t = \varepsilon_t$$

où le processus $(\varepsilon_t)_{t \in Z}$ est un bruit blanc Gaussien de variance unitaire.

Mise en oeuvre
L'obtention d'une série de données, de taille n, à partir du processus AR, au moyen d'une simulation par le logiciel S-Plus, se fait avec la fonction **arima.sim()**, et la trajectoire par la fonction **ts.plot()**.

Les commandes suivantes permettent de générer et de tracer une trajectoire de longueur **n**, issue du processus AR(2), ci-dessus (voir fig 2).

```
arima.sim(list(ar=c(0.4, 0.2)), n).
serie.sim<-arima.sim(list(ar=c(0.4, 0.2)), n).
ts.plot(serie.sim)
```

2.3.2 Processus moyenne mobile (Processus MA, Moving Average)

Ce sont des processus obtenus à partir d'un bruit blanc et de ses retards. Ils ont été introduits en 1927, par Slutsky.

Définition 15
On appelle ***processus moyenne mobile*** *d'ordre q, $MA(q)$, tout processus stationnaire $(X_t)_{t \in \mathbb{Z}}$ tel que*

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - ... - \theta_q \varepsilon_{t-q} \quad où \ \ \varepsilon_t \sim BB(0, \sigma_\varepsilon^2) \ \ (\theta_i)_{i=1,...,q} \in \mathbb{R}^q \ et \ \theta_q \neq 0.$$

Définition 16
Un processus stationnaire $(X_t)_{t \in \mathbb{Z}}$ suit un modèle MA(q) si il vérifie l'équation suivante :

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - ... - \theta_q \varepsilon_{t-q} \quad où \ \ \varepsilon_t \sim BB(0, \sigma_\varepsilon^2) \ \ (\theta_i)_{i=1,...,q} \in \mathbb{R}^q \ et \ \theta_q \neq 0.$$

Que l'on peut réécrire sous forme condensée par l'équation :

$$X_t = \Theta(B)\varepsilon_t$$

$\Theta(.)$ *est appelé polynôme moyenne mobile d'ordre q.*

Remarque
Un processus MA est automatiquement centré et stationnaire ; Un processus MA est par définition purement innovant et causal.

Remarque
Si toutes les racines du polynôme $\Theta(z)$ sont en dehors du cercle unité (i.e. si $\Theta(z)$ n'a pa de racine de module inférieure ou égale à 1), ce qu'on supposera dans la suite, alors on peut inverser l'opérateur $\Theta(z)$ et (X_t) peut s'exprimer sous la forme $AR(+\infty)$:

$$\varepsilon_t = \Theta^{-1}(B)X_t = \sum_{j=0}^{+\infty} \beta_j X_{t-j} \quad \text{où} \quad \begin{cases} \beta_0 = 1 \\ et \\ \sum_{j=0}^{+\infty} |\beta_j| < \infty \end{cases}$$

ce qui est équivalent à écrire $\quad X_t = -\sum_{j=1}^{+\infty} \beta_j X_{t-j} + \varepsilon_t.$

Ainsi, X_t dépend de ε_t et de son passé, donc X_{t-1} dépend de ε_{t-1} et de son passé, cet ensemble $\{\varepsilon_{t-1}, \varepsilon_{t-2}, ...\}$ étant indépendant de ε_t, donc le passé de X_t est indépendant de ε_t, donc ε_t est l'innovation de X_t. On dit dans ce cas que $(X_t)_{t\in\mathbb{Z}}$ est **inversible**.

Définition 17
*Un processus $(X_t)_{t\in\mathbb{Z}}$ est dit **inversible** lorsqu'il existe une suite de nombres (β_j) telle que $\sum_{j\in\mathbb{Z}} |\beta_j| < \infty$ et*

$$\varepsilon_t = \sum_{j=0}^{\infty} \beta_j X_{t-j}$$

Par définition, nous remarquons immédiatement que tout processus *autorégressif* est automatiquement ***inversible***.

Théorème 18
*Un processus $MA(q)$ est dit **inversible** si toutes les racines du polynôme Θ sont en dehors du cercle unité.*

L'inversibilité de $(X_t)_{t\in\mathbb{Z}}$ permet d'obtenir chaque valeur présente de la série en fonction des valeurs passées, d'où l'intérêt de l'inversibilité d'un processus pour la prévision.
En effet

$$\hat{X}_t = -\sum_{j=1}^{+\infty} \beta_j X_{t-j}$$

est le meilleur prédicteur linéaire de X_t sachant $X_{t-1}, X_{t-2}, ...$ et $\varepsilon_t = X_t - \hat{X}_t$ est l'innovation de $(X_t)_{t\in\mathbb{Z}}$ à l'instant t.

Définition 19
*X_t est **inversible** si est seulement si les poids les plus importants sont liés aux observations les plus récentes.*

Exemple
Soit X_t un processus MA(1) : $X_t = \varepsilon_t + \theta\varepsilon_{t-1}$.
Ce processus est-il inversible ?

Fonction d'autocovariance
Calculons la fonction d'autocovariance

$$\gamma(h) = E(X_t X_{t-h}) = ?$$

Après calcul, on en déduit que

$$\gamma(h) = \begin{cases} \sigma_\varepsilon^2 \sum_{j=0}^{q-h} \theta_j \theta_{h+j} \quad avec\ \theta_0 = -1 & si \quad h \leq q \\ 0 & si \quad h > q \\ \sigma_\varepsilon^2 (1 + \sum_{i=1}^{q} \theta_i^2) & si \quad h = 0. \end{cases}$$

Fonction d'autocorrélation

$$\rho(h) = \begin{cases} \frac{\sum_{j=0}^{q-h} \theta_j \theta_{h+j}}{1+\sum_{i=1}^{q} \theta_i^2} & si \quad h \leq q \\ 0 & si \quad h > q \\ 1 & si \quad h = 0. \end{cases}$$

Propriété 20
Pour un processus MA(q), on a $\rho(h) = 0$ si $h > q$.
Celà veut dire que les autocorrélations s'annulent à partir du rang $q + 1$.
Cette propriété est fondamentale pour la détermination de l'ordre d'un processus $MA(q)$.

Exemple
On considère

$$X_t = \varepsilon_t + \theta \varepsilon_{t-1} \quad \text{où} \quad |\theta| < 1$$

où (ε_t) est un processus stationnaire de moyenne nulle et de variance σ^2 et telle que $Cov(\varepsilon_t, \varepsilon_s) = 0$ si $t \neq s$.
Calculer la fonction d'autocorrélation du processus.

Fonction d'autocorrélation partielle (PACF)
Pour calculer la fonction d'autocorrélation partielle d'un processus $MA(q)$, on utilise le même algorithme que celui d'un processus AR(p) (l'algorithme de Durbin (1960)). Cependant, il faut noter que cette fonction d'autocorrélation partielle n'a pas de propriété particulière en effet, les valeurs de la fonction d'autocorrélation partielle ne s'annulent pas lorsque $h > q$.
Pour un $MA(1)$, $X_t = \varepsilon_t + \theta \varepsilon_{t-1}$ avec $|\theta| < 1$, on trouve

$$r_k = \frac{(-1)^{k+1} \theta^k (1 - \theta^2)}{1 - \theta^{2(k+1)}} \quad \text{pour } k \geq 2.$$

De façon générale, la fonction d'autocorrélation partielle r_k tend vers 0 à vitesse exponentielle pour tout $MA(q)$.

Le logiciel **R** permet de simuler des trajectoires finies engendrées par un processus MA. Par exemple, on s'intéresse au processus centré MA(2), tel que :

$$X_t = (1 - 0.4B - 0.2B^2)\varepsilon_t$$

où le processus $(\varepsilon_t)_{t \in Z}$ est un bruit blanc Gaussien de variance unitaire.

Mise en oeuvre
Comme dans le cas d'une simulation d'un AR, on utilise la fonction **arima.sim()**.

La commandes suivante permet de générer une trajectoire de longueur **n**, issue du processus MA(2), ci-dessus (voir fig.) :

```
arima.sim(list(ma=c(0.4, 0.2)), n)
```

2.4 Modèle composé : ARMA

Ce chapitre est consacré aux processus ARMA à coefficients constants, principalement aux processus univariés. Les résultats sont bien connus (par exemple, Quenouille, 1957, Hannan, 1970, Fuller, 1976, Rozanov, 1967 et Priestley, 1981).

Plusieurs processus aléatoires stationnaire ne peuvent être modélisés uniquement comme des processus MA purs ou AR purs car leurs caractéristiques sont souvent des combinaisons de deux types de processus. Ainsi, une classe de processus combinant les processus AR et MA a été développée par Box & Jenkins en 1970 : les modèles ARMA.

Définition 21
*$(X_t)_{t\in\mathbb{Z}}$ est un **processus ARMA(p, q)** s'il est stationnaire et sssi, pour tout $t \in \mathbb{Z}$, il vérifie l'équation suivante :*

$$X_t - \phi_1 X_{t-1} - ... - \phi_p X_{t-p} = \varepsilon_t - \theta_1 \varepsilon_{t-1} - ... - \theta_q \varepsilon_{t-q}, \qquad (*)$$

$$\text{où } (\phi_i)_{i=1,...,p} \in \mathbb{R}^p \text{ et } (\theta_i)_{i=1,...,q} \in \mathbb{R}^q \text{ avec } \phi_p \neq 0 \text{ et } \theta_q \neq 0$$

où $\varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$.

Le processus $(X_t)_{t\in\mathbb{Z}}$ est dit un **processus ARMA(p, q) avec mean** μ si $(X_t - \mu)_{t\in\mathbb{Z}}$ est un processus ARMA(p, q).

Il est convenant d'utiliser la forme la plus concise de (*)

$$\Phi(B)X_t = \Theta(B)\varepsilon_t \tag{6}$$

où $\Phi(.)$ et $\Theta(.)$ des polynômes de degrés p et q, représentent respectivement les polynômes autorégressif et moyenne mobile et n'ont pas de racine commune,

$$\Phi(z) = 1 - \phi_1 z - ... - \phi_p z^p \quad et \quad \Theta(z) = 1 - \theta_1 z - ... - \theta_q z^q$$

Propriété 22
Soit $(X_t)_{t\in\mathbb{Z}}$ un processus $ARMA(p,q)$: $\Phi(B)X_t = \Theta(B)\varepsilon_t$.

- *Si toutes les racines du polynôme $\Phi(B)$ ne sont pas sur le cercle unité c'est à dire si le polynôme $\Phi(B)$ ne s'annule pas sur le cercle défini par $|z| = 1$, alors le processus $(X_t)_{t\in\mathbb{Z}}$ est un processus linéaire stationnaire, oubien il existe une unique solution stationnaire $(X_t)_{t\in\mathbb{Z}}$.*
- *Si toutes les racines du polynôme $\Phi(B)$ sont en dehors du cercle unité c'est à dire si le polynôme $\Phi(B)$ ne s'annule pas sur le cercle défini par $|z| \leq 1$, c'est à dire $\Phi(z) \neq 0, \forall z \in \mathbb{Z}$ tel que $|z| \leq 1$, ce qu'on supposera dans la suite, le processus $(X_t)_{t\in\mathbb{Z}}$ sera dit **causal**, et alors $(X_t)_{t\in\mathbb{Z}}$ peut se réécrire sous sa forme moyenne mobile infinie $(MA(\infty))$, et on a :*

$$X_t = \Phi^{-1}(B)\Theta(B)\varepsilon_t \Longrightarrow X_t = \sum_{j\geq 0} \alpha_j \varepsilon_{t-j} \text{ où } \left\{ \begin{array}{c} \alpha_0 = 1 \\ \sum_{j\geq 0} |\alpha_j| < +\infty \end{array} \right.$$

- *Si toutes les racines du polynôme $\Theta(B)$ sont en dehors du cercle unité c'est à dire si le polynôme $\Theta(B)$ ne s'annule pas sur le cercle défini par $|z| \leq 1$, ce qu'on supposera dans la suite, le processus $(X_t)_{t\in\mathbb{Z}}$ sera dit **inversible**, et alors $(X_t)_{t\in\mathbb{Z}}$ peut se réécrire sous sa forme autorégressive infinie $(AR(\infty))$, et on a :*

$$\varepsilon_t = \Phi(B)\Theta^{-1}(B)X_t \Longrightarrow \varepsilon_t = \sum_{j\geq 0} \beta_j X_{t-j} \text{ où } \left\{ \begin{array}{c} \beta_0 = 1 \\ \sum_{j\geq 0} |\beta_j| < +\infty \end{array} \right.$$

- *Si les deux dernières conditions sont vérifiées, le processus $(\varepsilon_t)_{t\in\mathbb{Z}}$ est l'innovation du processus X_t et la représentation $\Phi(B)X_t = \Theta(B)\varepsilon_t$ est dite **canonique**.*

Définition 23
La représentation $\Phi(B)X_t = \Theta(B)\varepsilon_t$ sera dite ***canonique*** *(c'est à dire l'écriture du modèle ARMA est telle que ε_t soit le processus d'innovation de X_t) si elle est causale et inversible.*

Exemples

1. Soit X_t un processus $AR(1)$, définit comme suit :

$$X_t = \phi X_{t-1} + \varepsilon_t \quad avec \quad \varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$$

la racine du polynôme $\Phi(z) = 1 - \phi z$ est $z = \frac{1}{\phi}$.
– si |z|=1, ce qui implique $|\phi| = 1$, alors la forme $MA(\infty)$ n'existe pas, la représentation est non stationnaire, il s'agit d'une marche aléatoire, donc non causale, donc non canonique.
– si |z|<1, ce qui implique $|\phi| > 1$, alors

$$X_t = (1 - \phi B)^{-1}\varepsilon_t = -\sum_{i=1}^{\infty} \phi^{-i} B^{-i} \varepsilon_t = -\sum_{i=1}^{\infty} \frac{1}{\phi^i} \varepsilon_{t+i}$$

La forme $MA(\infty)$ n'est pas tournée vers le passé, la représentation n'est donc pas canonique.

2. Soit X_t un processus $MA(1)$, définit comme suit

$$X_t = \varepsilon_t - \theta\varepsilon_t \quad avec \quad \varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$$

la racine du polynôme $\Theta(z) = 1 - \theta z$ est $z = \frac{1}{\theta}$.
– si |z|=1, ce qui implique $|\theta| = 1$, alors la forme $AR(\infty)$ n'existe pas, la représentation est stationnaire, causale mais non inversible, donc non canonique
– si |z|<1, ce qui implique $|\theta| > 1$, alors

$$\varepsilon_t = (1 - \theta B)^{-1} X_t = -\sum_{i=1}^{\infty} \theta^{-i} B^{-i} X_t = -\sum_{i=1}^{\infty} \frac{1}{\theta^i} X_{t+i}$$

La forme $AR(\infty)$ de X_t n'est pas tournée vers son passé, la représentation n'est donc pas canonique.

Cependant, dans les deux cas de non canonique des représentations, on peut toujours (tant que, respectivement, $|\phi| \neq 1$ et $|\theta| \neq 1$) se ramener à une représentation canonique, en changeant la représentation, en changeant surtout de bruit blanc et en inversant les racines.

3. Soit X_t un processus $ARMA(1,1)$, définit comme suit

$$X_t = \phi X_{t-1} + \varepsilon_t - \theta\varepsilon_{t-1} \quad avec \quad \varepsilon_t \sim BB(0, \sigma_\varepsilon^2).$$

Les racines des polynômes $\Phi(z) = 1 - \phi z$ et $\Theta(z) = 1 - \theta z$ sont respectivement $z_1 = \frac{1}{\phi}$ et $z_2 = \frac{1}{\theta}$.
– si $|z_1| \leq 1$, ce qui implique $|\phi| \geq 1$, la représentation est non causale, donc non canonique.
– si $|z_2| \leq 1$, ce qui implique $|\theta| \geq 1$, la représentation est non inversible, donc non canonique.

Dans la suite on ne considérera que des processus $ARMA(p,q)$ à représentation canonique, c'est-à-dire inversibles et causaux.

Fonction d'autocovariance et Fonction d'autocorrélation.
La fonction d'autocovariance est définie par

$$\gamma(h) = E(X_t X_{t-h}) = ?$$

Après calcul, on a

$$\gamma(h) = \begin{cases} \sum_{i=1}^{p} \phi_i \gamma(h-i) \quad \text{pour } h > q \ (ou\ h \geq \max(p, q+1)) \\ \sum_{i=1}^{p} \phi_i \gamma(h-i) + \sigma_\varepsilon^2 \sum_{h \leq j \leq q} \theta_j \psi_{j-h} \quad \text{pour } \ 0 \leq h < \max(p, q+1) \\ \sum_{i=1}^{p} \phi_i \gamma(i) + \sigma_\varepsilon^2 \Big(1 - \sum_{j=1}^{q} \theta_j \psi_j\Big) \quad \text{pour } h = 0 \end{cases}$$

avec

$$\psi_j = \theta_j - \sum_{i=1}^{j} \phi_i \psi_{j-i} \quad 0 \leq j \leq \max(p, q+1)$$

La fonction d'autocorrélation est donnée par

$$\rho(h) = \frac{\gamma(h)}{\gamma_0}$$

Exemple
On considère le processus $ARMA(1,1)$ suivant :

$$X_t - \phi X_{t-1} = \varepsilon_t - \theta \varepsilon_{t-1} \quad \text{où } \ |\phi| < 1 \ et \ |\theta| < 1 \ \ \varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$$

Calculer l'ACF du processus $(X_t)_{t \in \mathbb{Z}}$.

La fonction d'autocorrélation partielle (ACP)
L'ACP d'un processus $ARMA(p,q)$ se comporte comme celle d'un $MA(q)$. Le coefficient d'autocorrélation partielle ϕ_{hh} n'a pas d'expression simple.

Le logiciel **R** permet de simuler des trajectoires finies engendrées par un processus AR. Par exemple, on s'intéresse au processus centré ARMA(2,1), tel que :

$$(I - 0.4B - 0.2B^2)X_t = (I - 0.3B)\varepsilon_t$$

où le processus $(\varepsilon_t)_{t \in Z}$ est un bruit blanc Gaussien de variance unitaire.

Mise en oeuvre
Comme dans le cas d'une simulation d'un AR ou d'un MA, on réalise la simulation d'un ARMA à l'aide de la fonction **arima.sim()**.

Les commandes suivantes permettent de générer et de tracer une trajectoire de longueur **n**, issue du processus ARMA(2,1).

```
arima.sim(list(ar=c(0.4, 0.2), ma=0.3), n).
tsplot(serie.sim)
```

2.5 Densité spectrale des processus ARMA

Le spectre d'une chronique peut s'interpréter comme étant la décomposition de sa variance dans le domaine des fréquences. Le spectre est un graphique présentant en abscisse les fréquences d'apparution des cyclicités, ces fréquences s'exprimant : $\lambda = \frac{2\pi}{T}$ en radian.

Soit (X_t) un processus $ARMA(p,q)$ défini par l'équation (6), alors sa densité spectrale f_X est donnée par :

$$f(\lambda) = \frac{\sigma_\varepsilon^2}{2\pi}\frac{|\Theta(e^{-i\lambda})|^2}{|\Phi(e^{-i\lambda})|^2}, \quad -\pi \leq \lambda \leq \pi.$$

Pour un processus $ARMA(1,1)$: $X_t - \phi_1 X_{t-1} = \varepsilon_t - \theta_1 \varepsilon_{t-1}$, la densité spectrale est donnée par

$$f(\lambda) = \frac{\sigma_\varepsilon^2}{2\pi}\frac{1 - 2\theta_1 \cos\lambda + \theta_1^2}{1 - 2\phi_1 \cos\lambda + \phi_1^2}$$

2.5.1 Densité spectrale d'un AR(p)

Soit X_t un processus $AR(1)$ défini comme suit : $X_t - \phi X_{t-1} = \varepsilon_t, \quad \varepsilon_t, \sim \mathcal{N}(0, \sigma^2)$,

La densité spectrale de (X_t) est donnée :

$$f_X(\lambda) = \frac{\sigma_\varepsilon}{2\pi}|1 - \phi e^{-i\lambda}|^{-2} = \frac{\sigma_\varepsilon^2}{2\pi(1 - 2\phi\cos\lambda + \phi^2)},$$

Pour un processus $AR(2)$: $X_t - \phi_1 X_{t-1} - \phi_2 X_{t-2} = \varepsilon_t$, la densité spectrale est donnée par

$$f(\lambda) = \frac{\sigma_\varepsilon^2}{2\pi(1 - 2\phi_1(1-\phi_2)\cos\lambda - 2\phi_2\cos\lambda + \phi_1^2 + \phi_2^2)}$$

2.5.2 Densité spectrale d'un MA(q)

Soit un processus $MA(1)$: $X_t = \varepsilon_t - \theta\varepsilon_{t-1}$

Sa densité spectrale est donnée par :

$$f_X(\lambda) = \frac{\sigma_\varepsilon^2}{2\pi}(1 - 2\theta\cos\lambda + \theta^2)$$

Pour un processus $MA(2)$: $X_t = \varepsilon_t - \theta_1\varepsilon_{t-1} - \theta_2\varepsilon_{t-2}$, la densité spectrale est donnée par

$$f_X(\lambda) = \frac{\sigma_\varepsilon^2}{2\pi}(1 - 2\theta_1(1-\theta_2)\cos\lambda - 2\theta_2\cos 2\lambda + \theta_1^2 + \theta_2^2)$$

Les commandes suivantes permettent de représenter la densité spectrale
`spectrum(nomserie, plot=T)`.
`periodog(nomserie, graph=T)`

2.6 Extension des processus ARMA

2.6.1 Processus ARMA intégrés : ARIMA

L'objectif de cette section est d'inclure les composantes non stationnaires de tendance (trend) dans la modélisation des séries chronologiques.

Définition 24
Un processus du second ordre $(X_t)_{t\in\mathbb{Z}}$ suit un modèle ARIMA d'ordre p, d, q, noté, ARIMA(p,d,q), si et seulement si $\Delta^d X_t = (I-B)^d X_t$ suit un modèle ARMA(p,q)

Si Y_t suit un modèle ARMA, on a :

$$\Phi(B)Y_t = \Theta(B)\varepsilon_t$$

Posons $Y_t = (I-B)^d X_t$, on a :

$$\Phi(B)(I-B)^d X_t = \Theta(B)\varepsilon_t$$

Ici d est appelé l'ordre de différenciation (ou l'ordre d'intégration).

Stationnarité et différentiation
La série chronologique observée vérifie t-elle l'hypothèse de stationnarité au second ordre des modèles ARMA ? Pour celà, on visualise cette série et si elle semble répondre au critères de stationnarité (oscillations d'amplitudes pas trop variables autour d'une valeur constante au cours du temps), on pose $d = 0$. Sinon, il faut envisager une transformation stationnaire. Par exemple, les variables économiques sont souvent considérées non stationnaires, mais à accroissements stationnaires (i.e. variance constante).
Il est important de connaitre la nature de la non stationnarité afin de savoir quelle transformation lui appliquée.

- En présence d'une tendance déterministe, il faut regresser la série d'origine sur une constante et un trend. Puis, modéliser à l'aide d'un modèle ARMA la série des résidus de la regression.
- Si la tendance est stochastique, la meilleure méthode pour l'éliminer est de différencier la série : la différenciation est une opération simple qui consiste à calculer des variations successives des valeurs de la série. On l'utilise lorsque la moyenne d'une série varie au cours du temps. La différentiation d'ordre 1 transforme (X_t) en $(X_t - X_{t-1})$; la différentiation d'ordre d consiste à effectuer d différentiations d'ordre 1.

Exemple
Si (X_t) posséde une tendance stochastique, alors $Y_t = (1-B)X_t$ est différenciée.
La chronique (Y_t) est alors stationnaire et est modélisée par un processus ARMA.

$$\begin{aligned} Y_t &= (1-B)X_t \\ &= X_t - X_{t-1} \end{aligned}$$

Commentaire
Pour stationnariser la série X_t à tendance stochastique, on applique un filtre de la forme $(I-B)$. Ce filtre permet d'enlever la tendance stochastique de la série, ce qui revient donc à choisir l'entier d du processus ARIMA égale à 1.

Mise en oeuvre

```
serie<-arima.sim(list(ar=0.4, ma=0.2, order=c(1,1,1)), n)
seriec<-serie-mean(serie)
dseriec.cts<-diff(seriec.cts, lag=1)
```

Exemple de processus ARIMA
Comme premier exemple, on peut citer la marche aléatoire ("random walk"). Et on a,

$$X_t = X_{t-1} + \varepsilon_t$$

est un processus ARIMA(0,1,0).

2.6.2 Processus ARIMA Saisonniers : SARIMA

Si l'on veut en même temps traiter les saisonnalités de période S (sans supposer une répétition exacte, déterministe, des données), on est amené à définir les processus SARIMA.

Définition 25
Un processus du second ordre $(X_t)_{t\in\mathbb{Z}}$ centré est défini comme étant un processus $SARIMA(p,d,q)(P,D,Q)_S$ avec période S, si $Y_t = \nabla^d \nabla_S^D X_t = (1-B)^d(1-B^S)^D X_t$ est un processus ARMA stationnaire. Autrement dit s'il vérifie l'équation aux différences suivante :

$$\Phi_p(B)\Phi_P(B^S)(I-B)^d(I-B^S)^D X_t = \Theta_q(B)\Theta_Q(B^S)\varepsilon_t$$

oubien

$$\Phi_p(B)\Phi_P(B^S)Y_t = \Theta_q(B)\Theta_Q(B^S)\varepsilon_t$$

où ε_t est un bruit blanc centré de variance σ_ε^2, S est la saisonnalité du processus, d et D sont deux entiers correspnondant respectivement aux ordres de différentiation et de différentiation saisonnière, $\Phi_p(z) = 1 - \phi_1 z - ... - \phi_p z^p$ et $\Theta_p(z) = 1 - \theta_1 z - ... - \theta_q z^q$ correspondent respectivement aux polynômes autorégressif et moyenne mobile, définis en section 4, et où

$$\Phi_P(z) = 1 - \phi_1 z - ... - \phi_P z^P$$

$$\Theta_Q(z) = 1 - \theta_1 z - ... - \theta_Q z^Q$$

sont deux polynômes générateurs respectivement d'un AR(P) saisonnier et d'un MA(Q) saisonnier.

On dit que X_t est un $SARMA(p,q)(P,Q)$ s'il vérifie l'équation

$$\Phi_p(B)\Phi_P(B^S)X_t = \Theta_q(B)\Theta_Q(B^S)\varepsilon_t$$

Cette saisonnalité est appelée saisonnalité multiplicative et le modèle de modèle multiplicatif saisonnier.

Le choix des ordres saisonniers P et Q se fait en utilisant les même tests utilisés pour le choix des ordres non saisonniers p et q, à savoir le test de Bartlett et celui de Quenouille ; l'ordre de différentiation saisonnière D est choisi égale à 1, en présence d'une saisonnalité de période S.
Les processus saisonniers ont pour intérêt de traiter les chroniques avec tendance et saisonnalité.

Exemple
Si (X_t) a une composante saisonnière de période 12, alors $Y_t = (1-B^{12})X_t$ est désaisonnalisée.

La chronique (Y_t) est alors "saisonnièrement" stationnaire et est modélisée par un processus ARMA (saisonnier), auquel on superpose un ARMA classique.

$$\begin{aligned} Y_t &= (1-B^{12})X_t \\ &= X_t - X_{t-12} \end{aligned}$$

Commentaire
Pour stationnariser la série X_t saisonnière, on applique un filtre de la forme $(I - B^{12})$. Ce filtre permet de faire disparaître la saisonnalité de la série.

Mise en oeuvre
```
dseriec.cts<-diff(seriec.cts, lag=12)
```

Si (X_t) posséde une tendance et une saisonnalité de 12 mois, alors $Y_t = (1-B)(1-B^{12})X_t$ est stationnarisée.
La chronique (Y_t) est alors stationnaire et est modélisée par un processus ARMA classique.

$$\begin{aligned} Y_t &= (1-B)(1-B^{12})X_t \\ &= X_t - X_{t-1} - X_{t-12} + X_{t-13} \end{aligned}$$

Commentaire
Pour stationnariser la série X_t possédant une tendance stochastique et une saisonnalité, on applique successivement un filtre de la forme $(I-B)$ et un filtre de la forme $(I-B^{12})$. Dans un premier temps le filtre $(I-B)$ permet d'enlever la tendance stochastique de la série, et dans un second temps le filtre $(I-B^{12})$ permet de faire disparaître la saisonnalité.

Mise en oeuvre
```
dseriec.cts<-diff(seriec.cts, lag=1)
ddseriec.cts<-diff(dseriec.cts, lag=12)
```

Exemple de processus SARIMA

$$(1-B^4)X_t = (1-\theta_1 B)(1-\theta_{1,4}B^4)\varepsilon_t$$

soit

$$\begin{aligned} X_t - X_{t-4} &= (1-\theta_1 B - \theta_{1,4}B^4 + \theta_1\theta_{1,4}B^5)\varepsilon_t \\ &= \varepsilon_t - \theta_1\varepsilon_{t-1} - \theta_{1,4}\varepsilon_{t-4} + \theta_1\theta_{1,4}\varepsilon_{t-5} \end{aligned}$$

est un processus SARIMA(0,0,1)(0,1,1) avec période 4.

3 Modélisation univariée de Box-Jenkins

3.1 Les étapes de la méthode de Box-Jenkins

Dans cette section on étudie la modélisation des séries chronologiques au moyen des modèles ARMA, ARIMA et SARIMA. L'approche est essentiellement celle de Box et Jenkins (1976), compléter par Anderson (1977), Ljung et Box (1978), Roy (1982) . Pour un exposé plus détaillé, voir par exemple Gourieroux et Monfort (1983) ou Roy (1980).

La méthode se décompose en 7 étapes (Anderson, 1977) :
- familiarisation avec les données,
- analyse préliminaire,
- identification ou spécification du modèle,
- estimation des paramètres,
- validation par tests ou test d'adéquation du modèle,
- prévision,
- interprétation des résultats.

3.1.1 Familiarisation avec les données

Le statisticien commence par s'informer d'abord sur le domaine dont relèvent les données qu'il a à traiter. Il prend connaissance des théories existantes. Il s'enquiert de la manière dont les données ont été obtenues (précision, exactitude, périodicité inhérente au phénomène étudié, du manque d'homogénéité dans le temps, des événements qui ont pu affecter la grandeur étudiée). Il représente graphiquement les données.

Ensuite, il examine les graphiques en notant l'allure générale, l'existence d'une tendance ou d'une composantes périodique ou quasi périodiques, la présence de valeurs aberrantes, etc.

3.1.2 Analyse préliminaire

Il s'agit de prendre un certain nombre d'options :
- abandonner une partie des données au début de la série,
- enquêter au sujet des données aberrantes, puis effectuer des corrections
- suppléer les valeurs manquantes,
- transformer les données (logarithmes, inverses, racine carrée, etc.),
- choisir de travailler en différence ordinaire (opérateur ∇), différence saisonnière (∇_s) ou les deux différences ($\nabla\nabla_s$),
- etc, etc.

Ces options ne sont pas définitives. Elles doivent permettre de réaliser l'étape d'identification dans les meilleures conditions possibles.

3.1.3 Identification ou Spécification du modèle

L'étape d'identification ou de la spécification d'un processus ARIMA(p, d, q) consiste à observer la nature des fonctions empiriques d'autocorrélation et d'autocorrélation partielle, de la série elle-même, pour choisir les ordres des parties AR (choix de l'entier p) et MA (choix de l'entier q), ainsi que l'ordre d'intégration (choix de l'entier d), une fois la série stationnarisée.

Détermination des ordres p et q
Le choix des entiers p et q se fait à l'aide de l'ACF empirique et de la PACF empirique.

Théorème 26 ***Test de Bartlett***
Soit $(X_t)_{t\in\mathbb{Z}}$ un processus MA(q) stationnaire gaussien.
Sous l'hypothèse $H_0 : \rho(h) = 0$ pour $h > q$ (i.e. que les autocorrelations ne sont pas significativement differents de zero), on a quand $T \longrightarrow +\infty$

$$\sqrt{T}\hat{\rho}(h) \longrightarrow \mathcal{N}\Big(0, 1 + 2\sum_{i=1}^{q}\hat{\rho}^2(i)\Big)$$

Pour tester l'hypothèse H_0, on utilise le test de Student en compararant la statistique $t_{\hat{\rho}(h)} = \frac{\hat{\rho}(h)}{\hat{\sigma}_{\hat{\rho}(h)}}$, où $\hat{\sigma}_{\hat{\rho}(h)} = \left[\frac{1}{T}\Big(1 + 2\sum_{i=1}^{h-1}\hat{\rho}_X^2(i)\Big)\right]^{\frac{1}{2}}$, et la valeur critique d'une loi de Student à $T - q$ degrés de liberté.

Le test est bilatéral symétrique, la région de rejet de H_0 est $]-\infty, -t_{1-\frac{\alpha}{2}}] \cup [t_{1-\frac{\alpha}{2}}, +\infty[$.
– $|t_{\hat{\rho}(h)}| < t_{1-\frac{\alpha}{2}}$, on accepte l'hypothèse $H_0 : \rho(h)$ n'est pas significatif
– $|t_{\hat{\rho}(h)}| \geq t_{1-\frac{\alpha}{2}}$, on rejette l'hypothèse $H_0 : \rho(h)$ est significatif
Sous l'hypothèse $H_0 : \rho_X(h) = 0$, l'intervalle de confiance de $\hat{\rho}_X(h)$, au risque de premier espèce $\alpha = 5\%$ est donnée par : $\hat{\rho}_X(h) \in \left[0 \pm 1,96\frac{\sqrt{1 + 2\sum_{i=1}^{h-1}\hat{\rho}_X^2(i)}}{T^{1/2}}\right]$

Donc ce théorème nous permet d'identifier l'ordre q tout en sachant $\rho(h) = 0$ au-delà de q ie pour tout $h \geq q + 1$.

Théorème 27 ***de Quenouille***
Soit $(X_t)_{t\in\mathbb{Z}}$ un processus AR(p) stationnaire gaussien. Sous l'hypothèse $H_0 : \phi_{hh} = 0$ pour tout $h \geq p + 1$, on quand $T \longrightarrow +\infty$

$$\sqrt{T}\hat{\phi}_{hh} \longrightarrow \mathcal{N}(0, 1)$$

Pour tester la nullité des autocorrelation partielles, on compare la statistique $t_{\hat{\phi}_{hh}} = \frac{\hat{\phi}_{hh}}{\sqrt{\frac{1}{T}}}$ et la valeur critique d'une loi de student à $T - k$ degré de liberté où k est le nombre de paramètre à estimer.
– $|t_{\hat{\phi}_{hh}}| < t_{1-\frac{\alpha}{2}}$, on accepte l'hypothèse H_0
– $|t_{\hat{\phi}_{hh}}| \geq t_{1-\frac{\alpha}{2}}$, on rejette l'hypothèse H_0
Sous l'hypothèse $H_0 : \phi_{hh} = 0$, l'intervalle de confiance de $\hat{\phi}_{hh}$, au risque de premier espèce $\alpha = 5\%$ est donnée par : $\hat{\phi}_{hh} \in \left[0 \pm 1,96\frac{1}{T^{1/2}}\right]$

Donc ce théorème nous permet d'identifier l'ordre p tout en sachant $\phi_{hh} = 0$ au-delà de p i.e. pour $h \geq p + 1$.

Ces intervalles permettent de décider empiriquement quel est l'ordre p pour un processus $AR(p)$ et quel est l'ordre q pour un processus $MA(q)$. Ces ordres correspondent aux valeurs de h pour lesquelles l'ACF empirique et le PACF empirique se trouvent à l'extérieur des intervalles de confiance.

Détermination de l'entier d
Si la trajectoire observée est issue d'un processus stationnaire, on dira que $(X_t)_{t\in\mathbb{Z}}$ est intégré d'ordre zéro, sinon on suppose qu'il existe un entier $d > 0$ tel que $(I-B)^d X_t$ est stationnaire, et on dira que le processus $(X_t)_{t\in\mathbb{Z}}$ est intégré d'ordre d. Cependant dans la majorité des cas rencontrés en pratique, l'entier d correspondant à l'ordre d'intégration est inférieur ou

égal à 1. Ainsi pour déterminer d, dans le cas de la modélisation $ARIMA$, deux hypothèses s'imposent

$$H_0 : d = 0$$
$$\text{contre}$$
$$H_1 : d = 1.$$

On peut se servir des tests de racine unitaire de Dickey-Fuller (1979, 1981) ou de Phillips-Perron (1988) pour le choix de d à partir des données.

On retiendra en pratique, que la présence d'une tendance stochastique entraine le choix $d = 1$ et qu'une moyenne constante entraine le choix $d = 0$.

Le cas $d \in]0, 1[$ sera traité pour les modèles à longue mémoire, commme le modèle $FARIMA$.

3.1.4 Estimation des paramètres

Il existe de nombreuses méthodes concurrentes d'estimation des paramètres d'un processus ARMA. On se réfère à Box et Jenkins (1970), Brockwell et Davis (1987) ou Hamilton (1994) pour une revue des différentes méthodes d'estimation. Nous nous contentons de présenter ici la méthode de Yule-Walker pour estimer les paramètres d'un processus $AR(p)$ et la méthode de maximum de vraisemblance pour le cas des processus $ARMA(p, q)$.

Cas des processus $AR(p)$
Pour ce type de processus, nous proposons, pour l'estimation des paramètres, la méthode de Yule-Walker.
Soit $(X_t)_{t\in\mathbb{Z}}$ un processus $AR(p)$, défini par :

$$\Phi(B)X_t = \varepsilon_t \ , \ \varepsilon_t \sim BB(0, \sigma_\varepsilon^2)$$

ou par

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + ... + \phi_p X_{t-p} + \varepsilon_t \quad \text{où} \quad (\phi_i)_{i=1,...,p} \in \mathbb{R}^p$$

Les paramètres à estimer ici sont : $\phi_1, \phi_2, \ldots, \phi_p$ et la variance résiduelle, σ_ε^2.

On a, pour tout $h = 1, ..., p$

$$\sum_{i=1}^{p} \phi_i \rho(h-i) = \rho(h)$$

Equation de Yule-Walker

$$\sigma_X^2 = \sum_{i=1}^{p} \gamma(i)\phi_i + \sigma_\varepsilon^2$$

où σ_X^2 est la variance du processus $(X_t)_{t\in\mathbb{Z}}$, égale à γ_0, et σ_ε^2 est la variance du processus bruit blanc $(\varepsilon_t)_{t\in\mathbb{Z}}$.
En écriture matricielle, l'équation de Yule-Walker peut se mettre sous la forme suivante :

$$\begin{pmatrix} 1 & \rho_1 & \rho_2 & \cdots & \rho_{p-1} \\ \rho_1 & 1 & \rho_2 & \cdots & \rho_{p-2} \\ \vdots & \vdots & \ddots & & \vdots \\ \vdots & \vdots & & \ddots & \vdots \\ \rho_{p-1} & \rho_{p-2} & \cdots & \cdots & 1 \end{pmatrix} \begin{pmatrix} \phi_1 \\ \phi_2 \\ \vdots \\ \vdots \\ \phi_p \end{pmatrix} = \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \vdots \\ \rho_p \end{pmatrix}$$

$$\Gamma\phi^t = \rho^t$$

où Γ est la matrice de variance-covariance du processus $(X_t)_{t\in\mathbb{Z}}$.
Γ est symétrique et est à valeurs propres $\lambda_i > 0$, donc Γ est définie positive. Γ étant une matrice définie positive, Γ est donc régulière et admet donc une inverse Γ^{-1}.

$$\Gamma\phi^t = \rho^t \Longrightarrow \phi^t = \Gamma^{-1}\rho^t$$

Donc un estimateur de $\phi = (\phi_1, \phi_2, \ldots, \phi_p)$, noté $\hat{\phi}$, est donné par : $\hat{\phi}^t = \hat{\Gamma}^{-1}\hat{\rho}^t$

La variance résiduelle $\hat{\sigma}_\varepsilon^2$ est alors donnée par l'équation :

$$\begin{aligned}\hat{\sigma}_\varepsilon^2 &= \hat{\sigma}_X^2 - \sum_{i=1}^{p} \hat{\phi}_i\hat{\gamma}(i) \\ &= \hat{\gamma}(0) - \sum_{i=1}^{p} \hat{\phi}_i\hat{\gamma}(i)\end{aligned}$$

Proposition 3.1
La distribution des estimateurs de Yule-Walker $\hat{\phi}$ du model paramétrique d'un processus $AR(p)$ causal

$$X_t = \phi_1 X_{t-1} + ... + \phi_p X_{t-p} + \varepsilon_t.$$

est asymptotiquement normale,

$$\sqrt{n}(\hat{\phi} - \phi) \xrightarrow{d} \mathcal{N}(0, \sigma^2\Gamma_p^{-1})$$

et

$$\hat{\sigma}_\varepsilon \xrightarrow{d} \sigma_\varepsilon^2$$

Mise en oeuvre
R effectue cette estimation à l'aide de la fonction **ar()**, avec l'option par défaut *method="yule-walker"*.

Estimation d'un processu ARMA(p, q)
Dans ce cas, nous présentons la méthode d'estimation par maximum de vraisemblance (MLE). L'intérêt de cette méthode est qu'elle utilise toute l'information à court comme à long terme concernant les comportements des séries puisque sont estimés simultanément les paramètres autorégressif, moyenne mobile et le paramètre de différenciation fractionnaire d. La méthode s'inscrit dans le domaine temporel. On suppose que les résidus $\varepsilon_1, \ldots, \varepsilon_T$ suivent une loi normale de moyenne nulle et de variance σ_ε^2.
Notons $\theta = (\theta_1, \theta_2, \ldots, \theta_q, \phi_1, \phi_2, \ldots, \phi_p, \sigma_\varepsilon^2)$ le paramètre à estimer.

La méthode préconisée par Box et Jenkins (1976, p.211) conditionne la vraissemblance du processus sur les p premières valeurs observées, $X_1, \ldots, X_p$, du processus $(X_t)_{t\in\mathbb{Z}}$; et sur les q valeurs du processus gaussien $(\varepsilon_t)_{t\in\mathbb{Z}}$, telles que :

$$\varepsilon_p = \varepsilon_{p-1} = \ldots = \varepsilon_{p-q+1} = 0$$

Ainsi à partir de la suite $X_1, \ldots, X_T$, on peut alors calculer par itérations la suite $\varepsilon_{p+1}, \varepsilon_{p+2}, \ldots, \varepsilon_T$, de la manière suivante, pour tout $t = p+1, \ldots, T$:

$$\varepsilon_t = X_t - \phi_1 X_{t-1} - \ldots - \phi_p X_{t-p} + \theta_1\varepsilon_{t-1} + \ldots + \theta_q\varepsilon_{t-q}.$$

On suppose que les perturbations sont gaussiennes conditionnellement aux $X_t, t \leq p$, alors X_t, pour tout $t = p+1, ..., T$ est normalement distribué avec une moyenne égale à

$\phi_1 X_{t-1} - \ldots - \phi_p X_{t-p} + \theta_1 \varepsilon_{t-1} + \ldots + \theta_q \varepsilon_{t-q}$ et une variance égale à σ_ε^2.
La log-vraisemblance conditionnelle est alors donnée par l'équation suivante :

$$\begin{aligned} L_{BJ}(\theta) &= \log f(X_T, \ldots, X_{p+1} | X_p, \ldots X_1, \varepsilon_p = \ldots = \varepsilon_{p-q+1} = 0) \\ &= \log \prod_{t=p+1}^{T} f(X_t | \mathcal{F}_{t-1}) \\ & \quad \mathcal{F}_{t-1} = \sigma(X_{t-1}, \ldots, X_{p+1}, X_p, \ldots X_1, \varepsilon_p = \ldots = \varepsilon_{p-q+1} = 0) \\ &= -\frac{T-p}{2} \log(2\pi) - \frac{T-p}{2} \log(\sigma_\varepsilon^2) - \sum_{t=p+1}^{T} \frac{\varepsilon_t^2}{2\sigma_\varepsilon^2} \end{aligned}$$

L'estimateur du maximum de vraissemblance (EMV), noté $\hat{\theta}_{EMV}$, est le paramètre qui maximise la log-vraissemblance, i.e. :

$$\hat{\theta}_{EMV} = Arg \max_{\theta} L_{BJ}(\theta).$$

En pratique, les estimateurs du maximum de vraisemblance sont trouvés numériquement par des algorithms itératifs : on cherche le maximum de la fonction de vraisemblance numériquement (par exemple, par la méthode de Newton-Raphson), démarrant d'une valeur initiale pour le vecteur du paramètre recherché. Cette valeur initiale peut être fournie par les estimateurs de Yule-Walker ou par les estimateurs des moindres carrés. S-Plus utilise la méthode de type quasi-Newton présentée, par exemple, dans Denis et al. (1981).

Mise en oeuvre
Avec **R**, l'estimation des paramètres d'un processus ARMA se fait à l'aide de la fonction **arima()** qui prend en argument le nom de la série et le modèle spécifié.

```
arima(serie, order=c(1,0,1))

arima(seriec, order = c(1,1,1), seasonal = list(order=c(1,1,1), period=12))
```

Les `ARMA creux` ou `percés` sont estimés de la manière suivante :
Supposons que l'on dispose du processus $ARMA(3,4)$ suivant,

$$(I - \phi_1 B - \phi_3 B^3) X_t = (I - \theta_1 B - \theta_4 B^4) \varepsilon_t,$$

Avec S-PLUS, on spécifie ce modèle à l'aide de l'option **ar.opt** de la manière suivante :
`arma34creux.mod<-list(order=c(3,0,4), ar.opt=c(T,F,T), ma.opt=c(T,F,F,T))`
puis on utilse la fonction `arima()` de la même manière pour les ARMA classiques.

Remarque
La méthode des `MCO` est inapplicable pour les modèles $MA(q)$ et $ARMA(p,q)$, car ε_{t-q}, variable aléatoire explicative du modèle, est inobservable.
La méthode des `MCO` est applicable pour les modèles $AR(p)$ car les termes d'erreurs sont non corrélés et la variance non conditionnelle constante mais toutefois elle reste moins performant que l'estimateur de la vraisemblance maximale.

3.1.5 Validation par tests des modèles

La validation des processus estimés se fait à l'aide d'un test de significativité des paramètres et d'une analyse sur les résidus estimés permettant de tester les hypothèses effectuées sur le processus d'innovation $(\varepsilon_t)_{t \in \mathbb{Z}}$ Si plusieurs modèles sont valides, l'étape de validation se poursuit par la comparaison des qualités de ces derniers à l'aide de critères de choix.

Significativité des paramètres
Il est important de déterminer si les paramètres du modèle sont significativement différents de zéro. On suppose que l'on part d'un modèle $ARMA(p,q)$ et que l'on examine le test correspondant à l'hypothèse nulle $H_0 : p^{'} = p-1$ et $q^{'} = q$. On test ainsi l'hypothèse nulle de processus $ARMA(p-1,q)$ i.e.($\phi_p = 0$) contre l'hypothèse alternative de processus $ARMA(p,q)$ i.e. ($\phi_p \neq 0$). On utilisera dans ce cas le test de Student qui consiste à comparer la statistique $t_{\hat{\phi}_p} = \frac{\hat{\phi}_p}{\hat{\sigma}_{\hat{\phi}_p}}$ avec la valeur critique d'une loi de Student à $T-k$ degrés de liberté, où $k = p+q+1$ est le nombre de paramètres estimés,

$$\hat{\sigma}^2_{\hat{\phi}_p} = \frac{\hat{\sigma}^2_\varepsilon}{\sum_{t=1}^{n}(X_t - \overline{X})^2} \quad \text{où} \quad \hat{\sigma}^2_\varepsilon = \frac{1}{n-k}\sum_{t=1}^{n} e_t^2$$

$\hat{\sigma}_\varepsilon$ est appelé variance résiduelle.

Régle de décision
– Si $|t_{\hat{\phi}_p}| < t_{1-\frac{\alpha}{2}}$, on accepte l'hypothèse H_0 de processus $ARMA(p-1,q)$.
– Si $|t_{\hat{\phi}_p}| \geq t_{1-\frac{\alpha}{2}}$, on rejette H_0 et on retient un processus $ARMA(p,q)$.
Sous l'hypothèse $H_0 : \phi_p = 0$, pour le modèle, l'intervalle de confiance de $\hat{\phi}_p$, au risque de premier espèce $\alpha = 5\%$ est donnée par : $\hat{\phi}_p \in \left[0 \pm 1,96\hat{\sigma}_{\hat{\phi}_p}\right]$.
On peut appliquer un raisonnement similaire pour tester l'hypothèse nulle : $H_0 : p^{'} = p$ et $q^{'} = q-1$.

Mise en oeuvre
On compare donc la valeur absolue de chacun des paramètres estimés avec sa variance. Ainsi, si la valeur absolue du paramètre est plus grande que **1.96×l'écart-type** du paramètre, alors on rejette, au risque de $\alpha = 0.05$, l'hypothèse de nullité du paramètre. On suppose que les paramètres estimés sont dans `serie.fit` (`serie.fit<--arima(.,.)`).
Ce qui donne les commandes suivantes :

```
abs(serie.fit$ar)>1.96*sqrt(serie.fit$var.coef[1,1])
[1] T
abs(serie.fitl$ma)>1.96*sqrt(serie.fit$var.coef[2,2])
[1] T
abs(serie.fit$coef[1])>1.96*sqrt(serie.fit$var.coef[1,1])
[1] T
abs(serie.fit$coef[2])>1.96*sqrt(serie.fit$var.coef[2,2])
[1] T
```

Dans ce cas, on peut alors conclure à la significativité des paramètres du modèle, au risque $\alpha = 0.05$.

Analyse des résidus
Cette étape consiste à modéliser les résidus e_t. S'il n'y a pas de dépendance parmi ces résidus alors on peut considérer qu'ils sont i.i.d. et la modélisation de la série temporelle est achevée.

Les résidus provenant du modèle sont donnés par :

$$e_t = X_t - \sum_{i=1}^{\hat{p}} \hat{\phi}_i X_{t-i} - \sum_{j=1}^{\hat{q}} \hat{\theta}_j e_{t-j}$$

Tests de diagnostic résiduel
Les tests consistent à vérifier que les résidus suivent un bruit blanc, i.e. sont moyenne nulle, non-corrélés et ne présentent pas d'hétéroscédasticité.

– **Test de nullité de la moyenne des erreurs**
Le processus ε_t est supposé être un bruit blanc. Soit $(e_t)_{t=1,\ldots,T}$ la série des résidus issue du modèle, on teste alors

$$\begin{array}{l} H_0 : \tilde{e} = 0 \\ \text{contre} \\ H_1 : \tilde{e} \neq 0 \end{array}$$

où $\tilde{e}$ est le paramètre inconnu de la moyenne des résidus issus de l'estimation ARMA.
La statistique du test est

$$t_{\overline{e}} = \frac{\overline{e} - 0}{\sigma_{\overline{e}}}$$

Cette statistique, sous l'hypothèse nulle de moyenne nulle, suit asymptotiquement la loi student $t_{(T-(p+q+1))}$.

– **Test de non autocorrélation des erreurs**

- **Test de Portmanteau**
Pour tester si les résidus observés sont i.i.d. on peut se servir de la fonction d'autocorrélation empirique $\hat{\rho}_e$.
Pour tester la significativité globale des autocorrélations à l'aide d'une statistique, le test utilisé par les logiciels S-Plus et R est le **test *Portmanteau* de Box et Pierce (1970)**, basé sur la statistique suivante

$$BP_K = T \sum_{k=1}^{K} \hat{\rho}_e^2(k)$$

où

$$\hat{\rho}_e(k) = \frac{\sum_{t=1}^{T-k} (e_t - \overline{e})(e_{t+k} - \overline{e})}{\sum_{t=1}^{T} (e_t - \overline{e})^2}$$

est la fonction d'autocorrélation d'ordre k des résidus estimés sur l'échantillon de la série, T est la longueur de la série et K est le nombre de retards choisis pour calculer les autocorrélation et est conseillé d'être choisi proche du tiers du nombre d'observation, $K = \left[\frac{T}{3}\right]$.
Le test à effectuer sur la fonction d'autocorrélation des résidus est donc

$$\begin{array}{l} H_0 : \hat{\rho}_e(1) = \hat{\rho}_e(2) = \ldots = \hat{\rho}_e(K) = 0 \\ \text{contre} \\ H_1 : \text{il } \exists \text{ au moins un } h \text{ telle que } \hat{\rho}_e(h) \neq 0 \end{array}$$

c'est dire H_0 : les résidus sont un bruit blanc contre H_1 : les résidus ne sont pas un bruit blanc.

Cette statistique BP_K, sous l'hypothèse de non-corrélation des K premières valeurs de la série ($H_0 : \rho_e(1) = \rho_e(2) = ... = \rho_e(K) = 0$), suit asymptotiquement une distribution de χ^2 avec $K - (p + q)$ degrés de liberté, où p est l'ordre de la partie AR (saisonnier ou

non), q est l'ordre de la partie MA (saisonnière ou non) et K est le nombre de retards inclus dans la sommation. L'adéquation du modèle est rejetée au risque α, si :

$$BP_K > \chi^2_{K-(p+q)}(1-\alpha).$$

Régle de décision

- Si $BP_K > \chi^2_{(1-\alpha)}(K-(p+q))$, on rejette H_0 : les résidus ne sont pas un bruit blanc.
- Si la P-value< 0.05 alors on rejette l'hypothèse nulle au seuil de 5% et donc les résidus sont autocorrélés à l'ordre $K-(p+q)$.

Ljung et **Box** (1978) introduisent une modification de la statistique de BP_K qui améliore l'approximation vers la distribution de χ^2 lorsque la taille de l'échantillon est petite. Celle-ci est définie par

$$LB_K = T(T+2)\sum_{k=1}^{K}\frac{\hat{\rho}_e^2(k)}{T-k}.$$

Sous l'hypothèse nulle d'absence d'autocorrélation :

$$\hat{\rho}_e(1) = \hat{\rho}_e(2) = \ldots = \hat{\rho}_e(K) = 0$$

La statistique LB_K suit une loi de Khi-deux à $(K-p-q)$ degrés de liberté.

Mise en oeuvre

Pour effectuer ce test sur les résidus, on utilise, sous **R**, la fonction **tsdiag()**.
Cette fonction renvoie la trajectoire des résidus, l'ACF des résidus, le PACF et le graphique des résultats du test de portmanteau de Box et Pierce. On a :

```
tsdiag(serie.fit)
residus<--tsdiag(serie.fit, plot=F)$resid
```
// permet de recupérer la série des résidus.

Sous **R** la fonction **tsdiag()**.

```
tsdiag(serie.fit)
residus<--serie.fit$residual
```
// permet de recupérer la série des résidus.

Box.test(x, lag = 1, type = c("Box-Pierce", "Ljung-Box"))

L'option `lag=1` permet de choisir l'entier K. Ces tests de non-corrélation de type Portmanteau connus pour leur faible puissance sont à utiliser avec prudence.

- **Test de Durbin-Watson**

Le test développé par Durbin et Watson (1950, 1951, 1971) est procédure très largement utilisée. Ce test est basé sur l'hypothèse que les erreurs dans le modèle de régression sont générés par un `processus autorégressif d'ordre 1` observé à des périodes de temps réguliers

$$\varepsilon_t = \phi\varepsilon_{t-1} + \eta_t$$

où $\eta_t \sim \mathcal{N}(0, \sigma_\eta^2)$ et $|\phi| < 1$.

Sous forme $MA(\infty)$, on a

$$\varepsilon_t = \sum_{j=0}^{\infty}\phi^j\eta_{t-j}$$

On montre que

$$E(\varepsilon_t) = 0, \quad V(\varepsilon_t) = \sigma_\eta^2\Big(\frac{1}{1-\phi^2}\Big)$$

$$cov(\varepsilon_t, \varepsilon_{t-j}) = \phi^j \sigma_\eta^2 \Big(\frac{1}{1-\phi^2}\Big).$$

L'autocorrélation entre ε_t et ε_{t-1} ou l'autocorrélation d'ordre 1, est

$$\begin{aligned} \rho_1 &= \frac{cov(\varepsilon_t, \varepsilon_{t-1})}{\sqrt{V(\varepsilon_t)}\sqrt{V(\varepsilon_t)}} \\ &= \frac{\phi\sigma_\eta^2\Big(\frac{1}{1-\phi^2}\Big)}{\sqrt{\sigma_\eta^2\Big(\frac{1}{1-\phi^2}\Big)}\sqrt{\sigma_\eta^2\Big(\frac{1}{1-\phi^2}\Big)}} \\ &= \phi \end{aligned} \tag{7}$$

Le test permet ainsi de détecter une autocorrélation d'ordre 1 sous la forme

$$\varepsilon_t = \rho_1 \varepsilon_{t-1} + \eta_t$$

Le test de Durbin-Watson est un test statistique de présence de corrélation positive des erreurs du modèle de régression. Ainsi, les hypothèse du test sont

$H_0 : \rho(1) = 0$
contre
$H_1 : \rho(1) \geq 0$

La statistique du test est

$$DW = \frac{\sum_{t=2}^T (e_t - e_{t-1})^2}{\sum_{t=1}^T e_t^2} = \frac{\sum_{t=2}^T e_t^2 + \sum_{t=2}^T e_{t-1}^2 - 2\sum_{t=2}^T e_t e_{t-1}}{\sum_{t=1}^T e_t^2} \approx 2(1-\rho_e(1))$$

où $(e_t)_{t=1,\dots,T}$ est la série des résidus issue de l'estimation du modèle de régression. Cette approximation de DW, quant T est grand, vers $2(1-\rho_e(1))$ simplifie la lecture du test. Ainsi une valeur de DW proche de 0 signifie une autocorrélation positive, une valeur proche de 4 une autocorrélation négative et une valeur proche de 2 la non autocorrélation.

Durbin et Watson (1951) montrent que la distribution de la statistique DW oscille entre deux distributions $d_1(T)$ et $d_2(T)$.
Les valeurs de $d_1(T)$ et de $d_2(T)$ sont données par la table de Durbin.

Régle de décision
- Si $DW < d_1(T)$, on rejette H_0
- Si $DW > d_2(T)$, on accepte H_0
- Si $d_1(T) < DW < d_2(T)$, on ne peut rien conclure.

Mise en oeuvre

```
dwtest(formula, order.by = NULL, alternative = c("greater","two.sided","less"),
iterations = 15, exact = NULL, tol = 1e-10, data = list())
```

- **Tests d'homoscédasticité**
  Un bruit blanc est par définition homoscédastique. Tous les tests d'hétéroscédasticité peuvent ici être employés.

  - **Test d'hétéroscédasticité de ARCH**
    On teste alors

    $H_0 : V(\varepsilon_t) = cst = \sigma_\varepsilon^2$
    contre
    $H_1 : V(\varepsilon_t) = \sigma_t^2 = \alpha_0 + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_p \varepsilon_{t-p}^2$

La statistique du test est

$$\chi^2_{ARCH} = TR^2$$

où R^2 est le coefficient de détermination obtenu dans la régression des résidus carrés issus de la modélisation $ARMA$ sur les résidus carrés retardés jusqu'à l'ordre p et T la taille de la série.
Cette statistique, sous l'hypothèse nulle de variance constante, suit asymptotiquement la loi chi-deux à p degrés de liberté, χ^2_p.

– **Test de stabilité structurelle de Chow**
Ce test sert à comparer des variances des résidus sur des sous périodes de la chronique.

Considérons le modèle suivant

$$X_t = \begin{cases} \alpha_0 + \alpha_1 X_{t-1} + \alpha_1 X_{t-2} + \varepsilon_t, & si \quad t \leq \tau \\ \beta_0 + \beta_1 X_{t-1} + \beta_2 X_{t-2} + \varepsilon_t, & si \quad t > \tau. \end{cases}$$

Ce test permet de savoir si les paramètres sont identiques au cours de deux ou plusieurs sous périodes. La statistique du test, appelée statistique de Fisher, est donnée par

$$F = \frac{SCR_c - SCR_1 - SCR_2)/k}{(SCR_1 + SCR_2)/(n-2k)}$$

où SCR est la somme des carrés des résidus issus de la regression linéaire utilisant toutes les données, avant et après la rupture. $SCR1$ est la somme des carrés des résidus à partir de la régression linéaire du premier régime, $SCR2$ est la somme des carrés des résidus à partir de la régression linéaire du deuxième régime, n est le nombre total des observations, k est le nombre de paramètres à estimer.

Remarque
Si les résidus sont de moyenne nulle et ne sont pas corrélés, on peut parler de bruit blanc **mais** le phénomène de "volatility clustering" (agrégats de volatilité), à savoir que les périodes de forte volatilité alternent avec les périodes de faible volatilité et la distribution à queue épaisse (Kurtosis>3) peut se poser. Il faut dans ce cas regarder les autocorrélations des résidus au carré. Si ces derniers sont corrélés, on en déduit que les résidus sont `non-corrélés` mais pas `indépendants`. L'hypothèse de processus `ARIMA(p,d,q) pur` est donc rejetée. On est donc amené à modéliser la variance des erreurs. Le modèle le plus populaire est le modèle `GARCH(p,q)` (Generalized Auto Regressive Conditionnal Heteroscedasticity).

– **Tests de normalité**
Il existe deux grandes familles de Tests de Normalité :
  – La famille des `tests paramétriques`, on peut citer par exemple, les tests de Skewness, Kurtosis et Jarque-Bera. Pour ces tests paramétriques, on spécifie sous H_0, l'égalité entre le paramètre inconnu et une norme. Par exemple, on teste la normalité d'une variable aléatoire en égalisant le paramètre du Jarque-Bera à 0 sous H_0.
  Ces tests paramètrique sont asymptotiquement puissants ce qui signifie que l'on ne peut les appliquer à des séries d'observation que si l'on dispose d'un nombre d'observations suffisant, au minimum trente observations.
  – La famille des `tests non paramétriques`, on peut citer par exemple, les tests de Kolmogorov Smirnov, Cramér-Von Mise, Anderson Darling, Shapiro-Wilk et Shapiro-Francia. Pour ces tests on ne spécifie pas sous H_0 l'égalité d'un paramètre à une norme, mais de façon plus générale l'égalité entre les distributions de probabilité empirique et théorique.

Tests de Skewness et Kurtosis
On peut regarder les moments d'ordre supérieur et la distribution empirique des résidus estimés. On regarde particulièrement les moments d'ordre 3 et 4 qui correspondent respectivement au *Skewness* et au *Kurtosis* et qui sont estimés par leurs valeurs empiriques, $\hat{Sk}_e$ et $\hat{K}_e$, définies par :

$$\hat{Sk}_e = \frac{\mu_3}{\sigma^3} = \frac{\mu_3}{(\sigma^2)^{3/2}} = \frac{\frac{1}{T}\sum_{t=1}^{T}(e_t - \overline{e})^3}{\left(\frac{1}{T}\sum_{t=1}^{T}(e_i - \overline{e})^2\right)^{3/2}}, \qquad \hat{K}_e = \frac{\mu_4}{\sigma^4} = \frac{\mu_4}{(\sigma^2)^2} = \frac{\frac{1}{T}\sum_{t=1}^{T}(e_t - \overline{e})^4}{\left(\frac{1}{T}\sum_{t=1}^{T}(e_i - \overline{e})^2\right)^2}$$

où $\overline{e}$ est la moyenne empirique calculée sur l'ensemble de l'échantilon $e_1, ..., e_T$.

On sait que
- Pour une distribution symétrique, en particulier pour la loi normale, sa moyennne est son point symétrique et ses moments centrés d'ordre impaire sont nuls, donc son Skewness est nul.
- Pour une distribution normale, le Kurtosis est égale à 3.

Donc
- Si Skewness $\hat{Sk}_e = 0 \quad \Rightarrow$ la distribution des résidus est symétrique.
- Si Kurtosis $\hat{K}_e = 3 \quad \Rightarrow$ la distribution des résidus semble être normale.

Si ceci est vérifié on a : $e_t \sim \mathcal{N}(0, \sigma_\varepsilon^2)$.

On peut aussi se servir des lois limites suivantes pour effectuer les tests

$$\frac{Sk}{\sqrt{\frac{6}{T}}} \xrightarrow[T\to+\infty]{\mathcal{L}} \mathcal{N}(0,1) \ , \qquad \frac{K-3}{\sqrt{\frac{24}{T}}} \xrightarrow[T\to+\infty]{\mathcal{L}} \mathcal{N}(0,1)$$

Le test de Jarque et Bera
Pour tester la normalité, on peut aussi se servir du test de Jarque-Bera, proposé en 1980 par Carlos Jarque et Anil Bera. Il permet de tester simultanément l'absence d'asymétrie et d'aplatissement. Le test est basé sur la statistique suivante :

$$JB = \frac{T}{6}\hat{Sk}_e^2 + \frac{T}{24}(\hat{K}_e - 3)^2.$$

Sous l'hypothèse H_0 : de normalité des résidus, la statistique JB suit asymptotiquement un chi-deux à 2 degrés de liberté, χ_2^2.

La région critique pour un risque α du test est définie par

$$R.C. : JB > \chi^2_{1-\alpha}(2).$$

Donc si $JB \geq \chi^2_{1-\alpha}(2)$, on rejette l'hypothèse H_0 de normalité des résidus au seuil α.

Pour un risque $\alpha = 0.05$, le seuil critique est $\chi^2_{0.95}(2) = 5.99$.

Sous **R**
library(tseries)
jarque.bera.test(serie)

Il y a aussi des tests distributionnels des résidus comme `Fisher`, `Student`, qui testent la Gaussianité.

Quelques tests non paramétriques

– **Le test de Kolmogorov-Smirnov**
Lilliefors (1967) présente une table pour tester la normalité en utilisant la Statistique de Kolmogorov-Smirnov. La statistique du test de Kolmogorov est basée sur la distance maximale entre F et F_n et est définie par

$$D_n = \sup_{x \in \mathbb{R}} \left| F(x) - F_n(x) \right|$$

où F est la loi de distribution inconnue de X dont sa moyenne et sa variance sont estimées à partir de l'échantillon et F_n la distribution empirique de X obtenue à partir de l'échantillon. La distribution de la statistique D_n est indépendante de $F(x)$ si $F(x)$ est continue ; le test est donc un test non paramétrique.
La `loi limite de` D_n a été étudiée par Kolmogorov lorsque n tend vers l'infini et par F.J. Massey Jr pour les petites valeurs de n.
Suivant Kolmogorov, pour toute valeur de $z \geq 0$, on a

$$P\Big(D_n \leq \frac{z}{\sqrt{n}}\Big) \xrightarrow[n \to \infty]{} K(z)$$

où $K(z)$ est la fonction de distribution cumulée donnée par

$$K(z) = 1 - 2\sum_{k=1}^{\infty} (-1)^{k-1} e^{-k^2 z^2}$$

Pour $z < 0$ on a

$$P\Big(D_n \leq \frac{z}{\sqrt{n}}\Big) \xrightarrow[n \to \infty]{} K(z) = 0$$

La Table de $K(z)$ est calculée par N. Smirnov (1939).

Exemple
$K(0.30) \approx 0.00$, $K(0.5) \approx 0.036$, $K(1.5) \approx 0.978$,...

Pour les échantillons de petites taille, Massey a étudié la distribution de D_n et a publié une Table qui donne les valeurs D_n qu'on a la probabilité α de dépasser du fait du hasard.

$$P(D_n > D_{n,\alpha}) = \alpha$$

Dans sa Table, Massey admet qu'à partir d'un échantillon de taille $n = 36$ on peut utiliser la table de Kolmogorov-Smirnov qui donne les valeurs z aux seuils de confiance $0.80; 0.85; 0.90; 0.95$ et $0; 99$. Il prend en effet pour D_n la valeur $\frac{z}{\sqrt{n}}$, z étant tiré de la Table de Kolmogorov-Smirnov.

Exemple
Par exemple, à un risque $\alpha = 5\%$, la valeur critique de D_n pour $n = 10$ est 0.410. C'est à dire que dans 5% d'échantillons aléatoires de taille 10, le maximum absolue de d'écart entre la distribution cumulative de l'échantillon et la distribution cumulative de la population sera au moins 0.410.

Connaissant la répartition de la grandeur aléatoire D_n, on peut alors, avec un risque fixé à l'avance, conclure si l'écart maximum entre $F(x)$ et $\hat{F}_n(x)$ peut être imputé au hasard de l'échantillonnage ou, au contraire, est dû au fait que l'échantillon n'est pas extrait d'une population décrite par la fonction de distribution $F(x)$.

Le test à effectuer se présente comme suit :

$$\begin{aligned} H_0 &: F(x) = \hat{F}_n(x) \quad \forall x \\ H_1 &: \exists\, x : F(x) \neq \hat{F}_n(x). \end{aligned}$$

Pour tester la **normalité**, sous H_0 `la loi de` D_n est tabulée par Lilliefors (1967) ou par Dallal et Wilkinson (1986) qui ont fourni une version corrigée de la Table de Lilliefors. Ainsi, pour un seuil α fixé, on accepte H_0 si $D_n < K_{1-\alpha,n}$. Les valeurs $K_{1-\alpha,n}$ sont lues sur les Tables de Smirnov ou de Massey, mais peuvent aussi être calculées par simulation.

Mise en oeuvre : `ks.test(residusnormalise, rnorm)`

- **Le test Cramer-Von Mise** : `cvm.test(X)`
- **Le test d'Anderson-Darling** : `ad.test(X)`
- **Le test de Shapiro-Wilk** : `shapiro.test(X)`

Pour voir de prés la distribution empirique des résidus estimés e_t, on peut tracer l'histogramme et la densité de distribution des résidus standardisés à l'aide respectivement des fonctions **hist()** et **density()**.

Mise en oeuvre
On suppose avoir recupérer la série des résidus dans *residus*, on a :

```
hist(residus, main="histogramme des résidus")

plot(density(residus,na.rm=T),type="l",main="densité des residus",xlab="",ylab="")

matplot(density(residusstand)$x, cbind(density(residusstand)$y,
dnorm(density(residusstand)$x)), type="l", lty=c(3,1), main="Densités de
Distribution")
```

Remarque
La remise en cause de l'hypothèse de normalité de la série des résidus doit conduire à s'interroger sur l'existence de points extrêmes dans la série (considérés comme des points aberrants) et sur leur traitement.

Remarque
Quand l'hypothèse de bruit blanc est rejeté sur la série résiduelle, autrement dit si on a du bruit **correlé**, la regression linéaire peut être remplacée par une analyse plus fine en géostatistique, appellée `krigeage`.

Critères de choix des modèles
Après examen des coefficients et analyse des résidus, certains modèles sont écartés. Pour choisir le meilleur de ces modèles restants, pour la prévision de l'évolution future de la série à partir des données passées, on fait appel aux critères standards et aux critères d'information.

– **Critères standards** :
  – L'erreur absolue moyenne (Mean Absolute Error) :

$$MAE = \frac{1}{T}\sum_{t=1}^{T}|e_t|$$

  – Racine de l'erreur quadratique moyenne (Root Mean Squared Error) :

$$RMSE = \sqrt{\frac{1}{T}\sum_{t=1}^{T}e_t^2}$$

  – Ecart absolu moyen en pourcentage (Mean Absolute Percent Error) :

$$MAPE = 100\frac{1}{T}\sum_{t=1}^{T}\left|\frac{e_t}{X_t}\right|$$

  où e_t est le résidu du modèle $ARMA$ étudié, T le nombre d'observation de la série X_t.

  Plus la valeur de ces critères est faible, plus le modèle estimé est proche des observations. Le RMSE est très utile pour comparer plusieurs estimateurs, notamment lorsque l'un d'eux est biaisé. Si les deux estimateurs à comparer sont sans biais, l'estimateur le plus efficace est simplement celui qui a la variance la plus petite.

– **Critères d'information**
  Ces critère proposent la minimisation en (p, q) de la fonction considérée
  – Le critère d'Akaike (1969) :

$$AIC(p,q) = \log\hat{\sigma}_\varepsilon^2 + \frac{2(p+q)}{T}$$

  Si les vrais ordres du modèle sont (p_0, q_0), le critère AIC de manière pratique à tendance à choisir $\hat{p} > p_0$ et $\hat{q} > q_0$.
  Pour obtenir un estimateur de (p_0, q_0) consistant, on utilise la version modifiée du critère AIC : le critère BIC.
  – Le critère d'information bayesien d'Akaike (1977) ou de Schwarz (1978) :

$$BIC = \log\hat{\sigma}_\varepsilon^2 + (p+q)\frac{\log T}{T}$$

  Ce critère est plutôt recommandé pour les modèles $ARMA$.
  – Le critère d'information de Hannan-Quinn (1979) :

$$HQ = \log\hat{\sigma}_\varepsilon^2 + \alpha(p+q)\log\left(\frac{\log T}{T}\right),$$

  où α est une constante à spécifier ($\alpha > 2$), p est l'ordre de la partie AR et q est l'ordre de la partie MA.

On choisit le modèle qui minimise les critères standards et les critères d'information. Le modèle sélectionné sera alors utilisé pour la prévision.

Remarque
Le critère le plus utilisé est le critère AIC. Présenté en (1973) pour un ARMA(p, q), Akaike a démontré que le meilleur des modèles ARMA non filtré est celui qui minimise la statistique du critère de AIC.

3.1.6 Prévision

Considérons un processus $ARMA(p,q)$ défini par l'équation :

$$\Phi(B)X_t = \Theta(B)\varepsilon_t$$

On veut prédire les valeurs futures $X_{t+1}, ..., X_{t+h}$ de la série (X_t) à partir des valeurs observées $\{X_1, X_2, ..., X_t, \varepsilon_1, \varepsilon_2, ..., \varepsilon_t\}$.

Soit $\hat{X}_t(h)$ le prédicteur de $(X_t)_{t\in\mathbb{Z}}$ à l'instant t et à l'horizon $h > 0$ (oubien la valeur prévue au temps $t+h$ de (X_t) c'est à dire la valeur estimée de la valeur prévue pour l'instant futur $t+h$, calculée au moment présent t). Par définition, on a l'expréssion suivante :

$$\hat{X}_t(h) = E(X_{t+h}|I_t)$$

où $I_t = \sigma(X_1, \ldots, X_t, \varepsilon_1, \ldots, \varepsilon_t)$ est l'ensemble d'information disponible à la date t.
Ce prédicteur représente la meilleure prévision de la série X_t conditionnellement à l'ensemble d'information disponible.

Exemple
Soit un processus $ARMA(1,1)$ défini par l'équation suivante :

$$X_t = \phi_1 X_{t-1} + \varepsilon_t - \theta_1\varepsilon_{t-1}, \quad |\phi_1| < 1 \ et \ |\theta_1| < 1$$

Calculer les prévisions pour l'horizon $h > 1$.

Considérons la forme $MA(\infty)$ du processus $ARMA$, on a

$$\begin{aligned} \Phi(B)X_t = \Theta(B)\varepsilon_t \Leftrightarrow X_t &= \frac{\Theta(B)}{\Phi(B)}\varepsilon_t \\ &= \Psi(B)\varepsilon_t. \end{aligned}$$

Soit,

$$X_t = \varepsilon_t + \psi_1\varepsilon_{t-1} + \psi_2\varepsilon_{t-2} + \psi_3\varepsilon_{t-3} + ...$$

Donc la prévision théorique peut s'écrire de la forme suivante :

$$X_{t+h} = \varepsilon_{t+h} + \psi_1\varepsilon_{t+h-1} + \psi_2\varepsilon_{t+h-2} + \psi_3\varepsilon_{t+h-3} + ...$$

On a alors

$$\begin{aligned} \hat{X}_t(h) &= E(X_{t+h}|I_t) \\ &= E(\varepsilon_{t+h} + \psi_1\varepsilon_{t+h-1} + \psi_2\varepsilon_{t+h-2} + \psi_3\varepsilon_{t+h-3} + ...|I_t). \end{aligned}$$

Pour $h = 1$ et $h = 2$, on obtient respectivement :

$$\hat{X}_t(1) = \psi_1\varepsilon_t + \psi_2\varepsilon_{t-1} + ...$$

$$\hat{X}_t(2) = \psi_2\varepsilon_t + \psi_3\varepsilon_{t-1} + ...$$

Ainsi on en déduit

$$\begin{aligned} \hat{X}_t(h) &= \psi_h\varepsilon_t + \psi_{h+1}\varepsilon_{t-1} + \psi_{h+2}\varepsilon_{t-2} + ... \\ &= \sum_{i\geq 0}\psi_{h+i}\varepsilon_{t-i}. \end{aligned} \tag{8}$$

On définit ainsi, l'erreur de prévision $\hat{e}_{t+h}$ par,

$$\begin{aligned} e_{t+h} &= X_{t+h} - \hat{X}_t(h) \\ &= \varepsilon_{t+h} + \psi_1\varepsilon_{t+h-1} + \psi_2\varepsilon_{t+h-2} + ... + \psi_{h-1}\varepsilon_{t+1} \\ &= \sum_{i=0}^{h-1} \psi_i\varepsilon_{t+h-i} \quad \text{avec} \quad \psi_0 = 1. \end{aligned}$$

En supposant que ε_t est un bruit blanc gaussien de variance σ_ε^2, e_{t+h} obéit donc à une loi $\mathcal{N}(0, \sigma_e^2)$ où σ_e^2 la variance de l'erreur de prévision est donnée par

$$\begin{aligned} V(e_{t+h}) = E\Big(\sum_{i=0}^{h-1} \psi_i\varepsilon_{t+h-i}\Big)^2 &= \sum_{i=0}^{h-1} \psi_i^2 E(\varepsilon_{t+h-i})^2 \\ &= \sigma_\varepsilon^2(1 + \psi_1^2 + ... + \psi_{h-1}^2) \\ &= \sigma_\varepsilon^2 \sum_{i=0}^{h-1} \psi_i^2. \end{aligned}$$

La précision des estimations est donc d'autant plus forte que la variance du bruit blanc est faible. Et cette précision diminue quand on veut prévoir plus loin dans le futur car la variance de l'erreur de prévision, dépendant aussi de l'horizon h, devient élevée.

On peut enfin construire un intervalle de confiance autour des prévisions réalisées. En effet, par hypothèse les ε_t sont un bruit blanc gaussien ; la distribution conditionnelle de la valeur à prévoir est donc une variable aléatoire d'espérance $\hat{X}_t(h)$ et d'écart-type $\sigma(\hat{e}_{t+h})$.
Ainsi, la valeur observée :

$$\frac{X_{t+h} - \hat{X}_t(h)}{\sigma_\varepsilon\Big(\sum_{j=0}^{h-1} \psi_j^2\Big)^{1/2}} \quad \text{suit donc une loi normale} \quad \mathcal{N}(0,1).$$

Par conséquent, pour toute valeur de α comprise entre 0 et 1, la relation suivante est obtenue :

$$P\left[\hat{X}_t(h) - q_{1-\alpha/2} \times \hat{\sigma}_\varepsilon\Big(\sum_{j=0}^{h-1} \psi_j^2\Big)^{1/2} \leq X_{t+h} \leq \hat{X}_t(h) + q_{1-\alpha/2} \times \hat{\sigma}_\varepsilon\Big(\sum_{j=0}^{h-1} \psi_j^2\Big)^{1/2}\right] = 1 - \alpha$$

où $\hat{\sigma}_\varepsilon$ est l'estimation de l'écart-type σ_ε du bruit blanc et $q_{1-\alpha/2}$ le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée reduite ($\alpha = 5\% \Longrightarrow q_{1-\alpha/2} = 1.96$).

L'intervalle de confiance de la prévision, au seuil $\alpha\%$, est donc donné par :

$$X_{t+h} \in \left[\hat{X}_t(h) \pm q_{1-\alpha/2} \times \hat{\sigma}_\varepsilon\Big(\sum_{j=0}^{h-1} \psi_j^2\Big)^{1/2}\right]$$

On calcule les prévisions en utilisant, une version tronquée et corrigée de la moyenne de l'equation (8), voir Brockwell et Davis (1991), p. 533 :

$$\hat{X}_t(h) = \sum_{i=0}^{T-1+h} \psi_{h+i}\varepsilon_{t-i} \tag{9}$$

R effectue cette estimation à l'aide de la fonction **predict()**.

Mise en oeuvre

```
arima.prev<-predict(modelest, n.ahead=horizon)
arima.inf<-arima.prev$pred-1.96*arima.prev$pred
arima.sup<-arima.prev$pred+1.96*arima.prev$se
tsplot(serie, arima.prev$pred, arima.inf, arima.sup, main="prevision à
l'horizon h")
```

La modélisation univariée présente l'avantage de ne nécessiter que les seules informations passées de la série à prévoir. En revanche, pour étudier les agrégats macroéconomiques, la capacité d'un modèle à intégrer l'information exogène est essentielle.

Il convient dès lors d'examiner les différentes méthodes pour intégrer l'information exogène disponible dans des modèles dits multivariés.

Références

[1] Bosq, D et Lecoutre, J. P. (1992), Analyse et prévision des séries chronologiques, Masson.

[2] Box, G. E. P. et Jenkins, G. M. (1976), Time Series Analysis Forecasting and Control, Holden-Day, San Francisco (édition révisée).

[3] Box, G. E. P., Jenkins, G. M. et Reinsel G. C. (1994), Time Series Analysis, Forecasting and Control, Prentice-Hall Press, (3rd edition).

[4] Brockwell, P. J. and Davis, R. A. (1991), Times Series : Theory and Methods. Springer.

[5] Coutrot, B. et Droesbeke, F. (1984), Les méthodes de prévision, PUF.

[6] Droesbeke, J. J., Fichet, B. et Tassi, Ph. (1989), Séries Chronologiques : Théorie et Pratique des Modèles ARIMA, Economica, Paris.

[7] Gouriéroux, C. et Monfort, A. (1990), Séries temporelles et modèles dynamiques, 2e éd. Economica, Paris.

[8] Melard, G. (1990), Méthodes de prévision à court terme, Editions de l'Université de Bruxelles, Bruxelles, et Editions Ellipses, Paris.

[9] Lardic, S. et Mignon, V., (2002), Econométrie des séries temporelles macroéconomiques et financières, Economica.